



โครงการวิศวกรรมคอมพิวเตอร์

การวิเคราะห์เชิงความรู้สึกจากรีวิวร้านอาหารภาษาไทย

Sentiment Analysis on Thai-Language Restaurant Reviews

นาย วรินทร์ธร จำปาศรี รหัสนิต 6430300871

นางสาว อีสริยา ทองแพง รหัสนิต 6430301125

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ ศรีราชา

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา

ปีการศึกษา 2567



ใบรับรองโครงการวิศวกรรมคอมพิวเตอร์

ปริญญาวิศวกรรมศาสตรบัณฑิต (วิศวกรรมคอมพิวเตอร์และสารสนเทศศาสตร์)

ภาควิชาวิศวกรรมคอมพิวเตอร์

คณะวิศวกรรมศาสตร์ศรีราชา

เรื่อง การวิเคราะห์เชิงความรู้สึกจากรีวิวร้านอาหารภาษาไทย
Sentiment Analysis on Thai-Language Restaurant Reviews

นามผู้จัดทำ 1. นาย วรินทร์ธร จำปาศรี 6430300871
2. นางสาว อีสสรียา ทองแพง 6430301125

ได้พิจารณาเห็นชอบโดย

อาจารย์ที่ปรึกษาโครงการ

(ผศ.ดร.กรวิทย์ ออกผล)

กรรมการโครงการ

(ดร.จัญญา สัตยพานิช)

กรรมการโครงการ

(ผศ.ดร.วัชรพัฐ เมตตานันท)

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ ศรีราชา

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา รับรองแล้ว

(ผศ.ดร.นันทา จันทร์พิทักษ์)

หัวหน้าภาควิชาวิศวกรรมคอมพิวเตอร์

โครงการวิศวกรรมคอมพิวเตอร์ เรื่อง

การวิเคราะห์เชิงความรู้สึกจากรีวิวร้านอาหารภาษาไทย

Sentiment Analysis on Thai-Language Restaurant Reviews

โดย

นาย วรินทร์ธร จำปาศรี รหัสนิสิต 6430300871

นางสาว อีสริยา ทองแพง รหัสนิสิต 6430301125

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ ศรีราชา

มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตศรีราชา

ปีการศึกษา 2567

วรินทร์ธร จำปาศรี \ อิสสรียา ทองแพง \ 2567 \ การวิเคราะห์เชิงความรู้สึกจากรีวิว
ร้านอาหารภาษาไทย \ ปริญญาวิศวกรรมศาสตรบัณฑิต (วิศวกรรมคอมพิวเตอร์และ
สารสนเทศศาสตร์) \ ภาควิชาวิศวกรรมคอมพิวเตอร์ \ คณะวิศวกรรมศาสตร์ศรีราชา
\ อาจารย์ที่ปรึกษา: ดร.กรวิทย์ ออกผล \ ผู้ช่วยศาสตราจารย์ \ 75 หน้า

บทคัดย่อ

โครงการนี้มีวัตถุประสงค์เพื่อพัฒนาระบบวิเคราะห์เชิงความรู้สึก (Sentiment Analysis) จากข้อความ
รีวิวร้านอาหารภาษาไทย โดยจำแนกความคิดเห็นออกเป็นระดับ 1–5 ดาว เพื่อสะท้อนแนวโน้มความพึงพอใจของ
ผู้บริโภค และช่วยให้ผู้ประกอบการนำข้อมูลไปใช้ปรับปรุงการให้บริการได้อย่างเหมาะสม

ข้อมูลที่ใช้รวบรวมจาก Wongnai และ Google Maps จำนวน 7,200 รีวิว ซึ่งผ่านกระบวนการทำความสะอาด
และคัดเลือกข้อความที่มีความยาวระหว่าง 80–510 ตัวอักษร จากนั้นแบ่งเป็นชุดฝึก 6,000 แถว และชุด
ทดสอบ 1,200 แถว เพื่อใช้ในการฝึกโมเดล WangchanBERTa ซึ่งเป็นโมเดลภาษาไทยบนโครงสร้าง BERT

ผลการทดลองแสดงให้เห็นว่า โมเดลที่ได้รับการฝึกเพิ่มเติมสามารถจำแนกระดับดาวได้แม่นยำขึ้น ลด
ความคลาดเคลื่อนในคลาสที่ต่างกันมาก ได้ค่าความแม่นยำที่ 80.42% แม้ยังมีบางกรณีที่คลาดเคลื่อนในระดับ
ใกล้เคียง (+/- 1 ดาว) แต่โดยรวมถือว่าอยู่ในระดับที่น่าพึงพอใจ นอกจากนี้ ระบบยังถูกเชื่อมต่อกับเว็บไซต์เพื่อให้
ผู้ใช้สามารถวิเคราะห์ข้อความรีวิวและรับผลสรุปแบบเรียลไทม์ ช่วยให้ผู้บริโภคตัดสินใจเลือกร้านอาหารได้สะดวก
รวดเร็ว และสนับสนุนผู้ประกอบการในการปรับปรุงบริการได้ตรงจุดมากยิ่งขึ้น

Warintorn Jampasee \ Aissariya Thongpang \ 2024 \ Sentiment Analysis on Thai-Language Restaurant Reviews \ Bachelor of Engineering (Computer Engineering and Informatics) \ Department of Computer Engineering \ Faculty of Engineering at Siracha \ Project Advisor: Dr. Korawit Orkphol \ Assistant Professor \ 75 pages.

Abstract

This project aims to develop a sentiment analysis system for Thai-language restaurant reviews by classifying opinions into five-star rating levels. The primary objective is to reflect consumer satisfaction trends and provide insights for business owners to improve their services effectively. A total of 7,200 reviews were collected from Wongnai and Google Maps. After undergoing a cleaning process, reviews with a length between 80 and 510 characters were selected. The dataset was then divided into 6,000 entries for training and 1,200 entries for testing.

The model used in this study is WangchanBERTa, a pre-trained Thai language model based on the BERT architecture. After fine-tuning with the selected dataset, the model demonstrated improved performance in star rating classification, particularly in reducing misclassification across widely different classes. The model achieved an accuracy of 80.42%. While there were still occasional errors in adjacent ratings (± 1 star), the overall performance was considered satisfactory.

Additionally, the sentiment analysis system was integrated into a web interface, allowing users to input review texts and receive real-time sentiment summaries. This functionality helps consumers make more informed decisions when choosing restaurants and supports restaurant owners in identifying key areas for service improvement with greater precision.

กิตติกรรมประกาศ

โครงการ “การวิเคราะห์เชิงความรู้สึกจากวีดิทัศน์ร้านอาหารภาษาไทย” ฉบับนี้สำเร็จลุล่วงได้ด้วยความช่วยเหลือและการสนับสนุนจากหลายฝ่าย ข้าพเจ้าขอขอบพระคุณ อาจารย์ที่ปรึกษา ที่ได้สละเวลาให้คำชี้แนะและให้คำปรึกษาด้วยความเอื้ออาทรตลอดระยะเวลาการทำโครงการ ขอขอบคุณ คณาจารย์และคณะกรรมการ สำหรับความเห็นอันเป็นประโยชน์ที่ช่วยให้โครงการมีความสมบูรณ์ยิ่งขึ้น

ข้าพเจ้าขอขอบคุณ ครอบครัวและเพื่อนร่วมรุ่น ที่คอยให้กำลังใจและสนับสนุนจนทำให้ข้าพเจ้ามีกำลังใจในการทำงานอย่างเต็มที่ อีกทั้งขอบคุณ ภาควิชาและมหาวิทยาลัย ที่อำนวยความสะดวกด้านทรัพยากรและสถานที่

สุดท้ายนี้ ข้าพเจ้าขอขอบขอบคุณทุกท่านที่มีส่วนร่วมอย่างยิ่งในการทำให้โครงการนี้ประสบความสำเร็จตามเป้าหมายที่ตั้งไว้

นาย วรินทร์ธร จำปาศรี

นางสาว อีสริยา ทองแพง

เมษายน 2568

สารบัญ

ใบรับรองโครงงานวิศวกรรมคอมพิวเตอร์	ก
โครงงานวิศวกรรมคอมพิวเตอร์	ข
บทคัดย่อ	ค
Abstract	ง
กิตติกรรมประกาศ	จ
บทที่ 1	1
บทนำ	1
1.1 คำสำคัญ (Key Words)	1
1.2 หลักการและเหตุผล	1
1.3 วัตถุประสงค์	2
1.4 ปัญหาหรือประโยชน์เป็นเหตุผลให้พัฒนาระบบ	2
1.5 เป้าหมายและขอบเขตของโครงงาน	2
1.6 กลุ่มผู้ใช้งาน	3
1.7 ประโยชน์ที่ได้รับ	3
1.8 แผนการดำเนินงาน	3
บทที่ 2	4
ความรู้พื้นฐานและงานวิจัยที่เกี่ยวข้อง	4
2.1 งานที่เกี่ยวข้อง	4
2.2 ความรู้พื้นฐาน เทคนิค เทคโนโลยีและเครื่องมือที่ใช้	14
บทที่ 3	39
อุปกรณ์และวิธีการ	39
3.1 เนื้อเรื่องย่อ	39
3.2 รายละเอียดวิธีการ	45
3.2.1 การจัดเตรียมชุดข้อมูล (Dataset Preparation)	45
3.2.2 การปรับแต่งโมเดล (Fine-tuning)	46
3.2.3 การนำโมเดลมาใช้งานจริง	50

บทที่ 4	53
ผลการทดสอบ	53
4.1 ผลการสอบระบบโดยรวม	53
4.2 ผลการทดสอบโมเดลที่มีประสิทธิภาพดีที่สุด	57
4.2.1 สรุปผลการประเมินประสิทธิภาพของโมเดล.....	57
4.2.2 การทำนายผลด้วย Confusion Matrix.....	58
4.2.3 บทวิเคราะห์ผลการเปรียบเทียบ	58
4.3 ผลการทดสอบจากผู้ใช้งานจริง	59
4.3.1 แบบสอบถามของเว็บแอปพลิเคชันด้านการทำนายผลของโมเดล	59
4.3.2 แบบสอบถามของเว็บแอปพลิเคชันด้านการออกแบบเว็บไซต์	60
4.3.3 แบบสอบถามของเว็บแอปพลิเคชันด้านการนำไปใช้งานจริง	60
บทที่ 5	61
สรุปและข้อเสนอแนะ	61
5.1 สรุปและข้อเสนอแนะ.....	61
5.2 แนวทางการพัฒนา.....	61
ภาคผนวก	62
ก1	63
คู่มือการติดตั้งระบบ.....	63
ก2	64
คู่มือการใช้งาน	64
ก3	66
ผลการทดสอบแต่ละตัวอย่าง	66
ก4	67
ผลลัพธ์การตอบแบบสอบถามแต่ละบุคคล	67
ก5	70
แหล่งเก็บชุดข้อมูล โปรแกรม และโมเดลของโครงการ.....	70
เอกสารอ้างอิง.....	71

สารบัญตาราง

ตารางที่ 1.1 แผนการดำเนินงาน	3
ตารางที่ 3.1 ตารางแสดงตัวอย่างข้อมูลฝึกฝน	42
ตารางที่ 3.2 ตารางแสดงตัวอย่างข้อมูลชุดทดสอบ	44
ตารางที่ 4.1 การทดสอบ DropOut	53
ตารางที่ 4.2 การทดสอบ Batch Size	54
ตารางที่ 4.3 การทดสอบ Epoch	54
ตารางที่ 4.4 การทดสอบ Data Size	54
ตารางที่ 4.5 ผลระหว่างการฝึกที่ดีที่สุด	55
ตารางที่ 4.6 ผลการทดสอบโมเดลพื้นฐาน (Base Model) เทียบกับ โมเดลที่ดีที่สุด (Final Model)	57
ตารางที่ 4.7 Classification Report ของโมเดลพื้นฐาน (Base Model) เทียบกับโมเดลที่ดีที่สุด (Final Model)	57

สารบัญภาพ

รูปภาพที่ 2.1 Encoder-decoder model architecture	14
รูปภาพที่ 2.2 ตัวอย่าง การประมวลผลของ RNN ซึ่งนำเข้าคำและข้อมูลจากคำก่อนหน้า ไปประมวลผล	15
รูปภาพที่ 2.3 ตัวอย่าง หนึ่งหน่วยประมวลผลของ CNN ซึ่งนำเข้า กลุ่มคำ ไปประมวลผล	16
รูปภาพที่ 2.4 ตัวอย่าง การส่งต่อข้อมูลใน CNN โดยยิ่งคำที่อยู่ใกล้กัน ยิ่งต้องอาศัยหลาย layers กว่าโมเดลจะเจอข้อมูลของทั้งสองคำ	17
รูปภาพที่ 2.5 ตัวอย่างทำงาน	18
รูปภาพที่ 2.6 Transformer Architecture.....	19
รูปภาพที่ 2.7 Input Embedding ของ Encoder.....	19
รูปภาพที่ 2.8 สิ่งที่เกิดขึ้นใน Input Embedding เพื่อเปลี่ยนตัวอักษรเป็นเวกเตอร์ตัวเลข	20
รูปภาพที่ 2.9 ค่า sin/cos ในการแทน position ต่าง ๆ.....	21
รูปภาพที่ 2.10 ภาพรวมของ Self-Attention	21
รูปภาพที่ 2.11 ตัวอย่างการคำนวณ Attention เวอร์ชันอย่างง่าย (no scaling and softmax).....	22
รูปภาพที่ 2.12 สมการการคำนวณ Attention.....	23
รูปภาพที่ 2.13 ตัวอย่างสิ่งที่เกิดขึ้นใน Multi-head attention unit.....	24
รูปภาพที่ 2.14 เส้นทางการทำ Residual connections	26
รูปภาพที่ 2.15 ส่วนประกอบใน Encoder.....	28
รูปภาพที่ 2.16 ส่วนประกอบใน Decoder	29
รูปภาพที่ 2.17 ภาพรวมของ Encoder และ Decoder.....	30
รูปภาพที่ 2.18 Encoder ที่ BERT นำของ Transformers มาใช้.....	31
รูปภาพที่ 2.19 ภาพรวม ในแต่ละรอบของการสอน BERT	31
รูปภาพที่ 2.20 ตัวอย่างการจัดการปัญหาของ BERT	33
รูปภาพที่ 3.1 ภาพรวมของระบบ.....	51
รูปภาพที่ 4.1 กราฟระหว่าง Training , Validation Loss เทียบ Epoch.....	56
รูปภาพที่ 4.2 กราฟระหว่าง Accuracy เทียบ Epoch	56
รูปภาพที่ 4.3 Confusion Matrix Base Model.....	58
รูปภาพที่ 4.4 Confusion Matrix Fine-Tune Model.....	58

รูปภาพที่ 4.5 ผลการตอบแบบสอบถามด้านการทำนายผลของโมเดล	59
รูปภาพที่ 4.6 ผลการตอบแบบสอบถามด้านการออกแบบเว็บไซต์	60
รูปภาพที่ 4.7 ผลการตอบแบบสอบถามด้านการนำไปใช้งานจริง	60
รูปภาพที่ ก.1.1 คิวอาร์โค้ดเข้าใช้งานเว็บไซต์	63
รูปภาพที่ ก.2.1 หน้าเว็บไซต์.....	65
รูปภาพที่ ก.3.1 ผลการทดสอบแต่ละตัวอย่าง.....	66
รูปภาพที่ ก.4.1 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – เพศ	67
รูปภาพที่ ก.4.2 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – อายุ.....	67
รูปภาพที่ ก.4.3 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – สถานภาพ	68
รูปภาพที่ ก.4.4 ผลลัพธ์การตอบแบบสอบถามด้านการทำนายผลของโมเดล.....	68
รูปภาพที่ ก.4.5 ผลลัพธ์การตอบแบบสอบถามด้านการออกแบบเว็บไซต์	69
รูปภาพที่ ก.4.6 ผลลัพธ์การตอบแบบสอบถามด้านการนำไปใช้งานจริง	69

บทที่ 1

บทนำ

1.1 คำสำคัญ (Key Words)

- การวิเคราะห์ความรู้สึก
- การตรวจจับอารมณ์
- Wongnai
- Google maps

1.2 หลักการและเหตุผล

การอ่านรีวิวออนไลน์อย่างละเอียดเป็นสิ่งที่ผู้บริโภคมักใช้ประกอบการตัดสินใจเลือกใช้บริการร้านอาหาร อย่างไรก็ตาม การมีเนื้อหาจรรยาบรรณที่หลากหลายและซับซ้อนอาจทำให้เกิดความลำบากในการตัดสินใจของผู้บริโภค เนื่องจากรีวิวในมุมมองที่แตกต่างส่งผลต่อการตัดสินใจ [1] นอกจากนี้ ยังมีร้านอาหารจำนวนมากที่ไม่ได้มีระบบการให้คะแนนหรือดาว [2] จึงอาจขาดข้อมูลเชิงปริมาณที่ชัดเจนให้กับผู้บริโภค รวมทั้งวิเคราะห์ความรู้สึกของรีวิวออนไลน์ในภาษาไทยยังมีความแม่นยำที่ต่ำกว่าในภาษาอื่น ๆ [3] ซึ่งเป็นอีกปัจจัยที่ทำให้ผู้บริโภคได้รับข้อมูลที่ไม่ตรงตามที่ต้องการอย่างเต็มที่

จากปัญหาที่กล่าวมา โครงการนี้จึงเสนอแนวคิดในการพัฒนาโมเดลวิเคราะห์ความรู้สึก สำหรับภาษาไทยที่สามารถรวบรวมและวิเคราะห์ความคิดเห็นของลูกค้าจากรีวิวร้านอาหาร โมเดลนี้จะช่วยให้สามารถแปลงข้อมูลเชิงความรู้สึกจากรีวิวเป็นคะแนนหรือระดับดาวที่สะท้อนคุณภาพโดยรวมของร้านได้ ด้วยการประยุกต์ใช้ Natural Language Processing [4] ในการตรวจจับอารมณ์ที่แฝงอยู่ในข้อความรีวิวภาษาไทย ทำให้ผู้บริโภคสามารถเข้าใจแนวโน้มของรีวิวได้โดยไม่ต้องอ่านทุกข้อความ

โครงการนี้มีประโยชน์อย่างมากในการพัฒนาระบบ Sentiment Analysis สำหรับภาษาไทยที่มีความแม่นยำสูงขึ้น โดยระบบนี้สามารถช่วยสรุปข้อมูลรีวิวระดับความรู้สึกได้ ซึ่งจะเป็นประโยชน์ต่อผู้บริโภคในการตัดสินใจเลือกใช้บริการร้านอาหารได้รวดเร็วและสะดวกมากขึ้น สำหรับร้านอาหารที่ไม่มีระบบให้คะแนนทำให้ผู้บริโภคมีข้อมูลประกอบการตัดสินใจที่ชัดเจนยิ่งขึ้น

1.3 วัตถุประสงค์

1.3.1 เพื่อพัฒนาระบบการวิเคราะห์ความรู้สึก (Sentiment Analysis) จากข้อความรีวิว (Review) ร้านอาหารในภาษาไทยจากแพลตฟอร์ม Wongnai และ Google maps โดยจะจำแนกความรู้สึกออกมาเป็น ความหมายทางอารมณ์ออกมาเป็น 5 ระดับ คือ แย่มาก, แย่, เฉย ๆ, ดี, ดีมาก

1.3.2 เพื่อพัฒนาระบบการวิเคราะห์ความรู้สึก (Sentiment Analysis) จากข้อความภาษาไทย เพื่อให้ได้มาซึ่งความแม่นยำ (Accuracy) ที่มากกว่าโมเดลที่มีอยู่แล้ว

1.3.3 เพื่อสร้างรายงานและสรุปผลการวิเคราะห์ที่นำเสนอข้อมูลโดยรวมของร้านอาหารต่าง ๆ เพื่อเป็น สิ่งที่ใช้ตัดสินใจในการเลือกใช้บริการ และเป็นประโยชน์แก่ผู้บริโภค (option)

1.4 ปัญหาหรือประโยชน์เป็นเหตุผลให้พัฒนาระบบ

ปัจจุบัน การแสดงความคิดเห็นต่อร้านอาหารผ่านสื่อออนไลน์มีจำนวนมาก ส่งผลให้การวิเคราะห์ความคิดเห็นทั้งหมดด้วยตนเองเป็นไปได้ยาก โดยเฉพาะอย่างยิ่ง การวิเคราะห์ความรู้สึกเชิงอารมณ์ (Sentiment Analysis) ในภาษาไทยซึ่งมีความซับซ้อนทางไวยากรณ์ มีการพิมพ์ต่อกันเป็นประโยคยาว และมีการใช้คำแสลง (slang) ที่อาจส่งผลให้โมเดลภาษาทั่วไปประมวลผลได้ไม่แม่นยำเท่าที่ควร [5] อีกทั้งยังมีร้านอาหารจำนวนมากที่ไม่ได้มีระบบการให้คะแนนหรือดาว จึงขาดข้อมูลเชิงปริมาณให้แก่ผู้บริโภค [2] ดังนั้น จึงมีความจำเป็นที่จะพัฒนาระบบ Sentiment Analysis ที่รองรับภาษาไทยโดยเฉพาะ เพื่อให้ได้ผลลัพธ์ที่มีความแม่นยำและสามารถนำไปประยุกต์ใช้ได้จริง โดยระบบดังกล่าวจะช่วยประมวลผลและสรุปความคิดเห็นจำนวนมากในรูปแบบที่เข้าถึงได้ง่าย และรวดเร็วยิ่งขึ้น ซึ่งจะเป็ประโยชน์ทั้งสำหรับผู้บริโภคและผู้ประกอบการในการทำมาเข้าใจความคิดเห็นและความพึงพอใจที่มีต่อร้านอาหารในสื่อออนไลน์ได้อย่างมีประสิทธิภาพมากขึ้น

1.5 เป้าหมายและขอบเขตของโครงการ

- 1.5.1 ระบบสามารถวิเคราะห์ความรู้สึกจากข้อความรีวิวภาษาไทย ด้วยความแม่นยำที่ค่อนข้างสูง สามารถนำไปใช้งานจริงได้
- 1.5.2 ระบบสามารถสร้างรายงานและสรุปผลการวิเคราะห์ที่นำเสนอข้อมูลโดยรวมของร้านอาหารต่าง ๆ ได้อย่างแม่นยำ
- 1.5.3 ระบบสามารถแสดงข้อมูลโดยรวมภายหลังจากการวิเคราะห์ออกมาได้ ในรูปแบบที่ผู้ใช้งานสามารถเข้าใจได้ง่าย
- 1.5.4 ระดับความแม่นยำของโมเดลที่เทรนต่อจาก WangchanBERTa ได้ค่าความแม่นยำในระดับที่เทียบเท่าหรือสูงกว่า

บทที่ 2

ความรู้พื้นฐานและงานวิจัยที่เกี่ยวข้อง

2.1 งานที่เกี่ยวข้อง

2.1.1 Sentiment Analysis: Mining Opinions, Sentiments, and Emotions (2020) [5]

การวิเคราะห์อารมณ์ (Sentiment Analysis) เป็นกระบวนการที่ใช้ในการทำความเข้าใจความคิดเห็นและอารมณ์ของผู้เขียนในข้อมูลข้อความ โดยมุ่งเน้นการตรวจสอบอารมณ์ที่แฝงอยู่ภายในข้อความ ซึ่งสามารถจำแนกออกได้เป็นเชิงบวก (positive), เชิงลบ (negative) และในบางกรณีอาจเป็นกลาง (neutral) แนวคิดหลักของการวิเคราะห์อารมณ์นั้นคือการทำให้เข้าใจมุมมองของผู้เขียนที่มีต่อประเด็นหนึ่ง ๆ เช่น ความคิดเห็นต่อสินค้า บริการ หรือบุคคล การจำแนกประเภทอารมณ์นี้สามารถทำได้หลายระดับ เช่น การวิเคราะห์ในระดับเอกสารทั้งหมด (Document-level) ระดับประโยค (Sentence-level) หรือการวิเคราะห์ในเชิงประเด็นเฉพาะ (Aspect-based Analysis) ซึ่งเจาะลึกถึงความคิดเห็นในมุมมองที่แตกต่างกันภายในข้อความเดียวกัน

แนวทางหลักที่ใช้ในการวิเคราะห์อารมณ์มีอยู่ 2 แนวทางหลัก ได้แก่ Lexicon-based Approach และ Machine Learning Approach ในการใช้ Lexicon-based Approach ระบบจะพึ่งพาพจนานุกรมที่รวบรวมคำที่ระบุอารมณ์ล่วงหน้าไว้แล้ว ซึ่งสามารถช่วยให้ระบบแยกแยะคำที่สื่อถึงอารมณ์เชิงบวกหรือลบได้ง่ายขึ้น อย่างเช่น คำว่า "ยอดเยี่ยม" อาจเชื่อมโยงกับอารมณ์เชิงบวก หรือคำว่า "น่าผิดหวัง" เชื่อมโยงกับอารมณ์เชิงลบ

อีกแนวทางหนึ่งคือการใช้ Machine Learning Approach ซึ่งใช้เทคนิคการเรียนรู้ของเครื่อง เช่น Naive Bayes และ Support Vector Machines (SVM) รวมถึงการประยุกต์ใช้ Neural Networks ที่สามารถฝึกโมเดลจากข้อมูลที่มีการบ่งบอกอารมณ์ไว้อย่างชัดเจน วิธีการนี้จะช่วยให้โมเดลสามารถเรียนรู้และจดจำลักษณะการแสดงออกของอารมณ์ในข้อความใหม่ ๆ ได้อย่างแม่นยำ ข้อดีของการใช้ Machine Learning คือสามารถวิเคราะห์ได้อย่างยืดหยุ่นมากขึ้นและมีประสิทธิภาพในการประมวลผลข้อความที่มีความซับซ้อนสูง

การวิเคราะห์ในเชิงประเด็น (Aspect-based Sentiment Analysis) เป็นแนวทางที่ใช้เพื่อเข้าใจความคิดเห็นในแต่ละประเด็นโดยเฉพาะ อย่างเช่น ในรีวิวร้านอาหาร ผู้เขียนอาจมีความคิดเห็นเชิงบวก

ต่อคุณภาพอาหารแต่รู้สึกไม่พอใจต่อการบริการ การวิเคราะห์ประเภทนี้ช่วยให้เข้าใจความคิดเห็นได้อย่างลึกซึ้งขึ้น เพราะเป็นการแยกแยะอารมณ์ที่มีต่อแต่ละส่วนของประสบการณ์การใช้งานหรือผลิตภัณฑ์ ซึ่งทำให้ผลลัพธ์ของการวิเคราะห์มีความสมบูรณ์และครอบคลุมยิ่งขึ้น

การวิเคราะห์อารมณ์ถูกนำไปประยุกต์ใช้ในหลายภาคธุรกิจ เช่น การติดตามความคิดเห็นของลูกค้าในโซเชียลมีเดีย การวิเคราะห์ความพึงพอใจของลูกค้า และการประเมินผลผลิตภัณฑ์ใหม่ ๆ โดยอาศัยข้อมูลเชิงอารมณ์จากการรีวิวหรือโพสต์ออนไลน์ ซึ่งเป็นการช่วยให้ธุรกิจสามารถตอบสนองต่อความต้องการของลูกค้าได้อย่างมีประสิทธิภาพ

ความสอดคล้องกับงาน : งานวิจัยนี้ครอบคลุมแนวทางการวิเคราะห์อารมณ์ที่สามารถนำมาใช้ในโปรแกรมการวิเคราะห์ความรู้สึกจากรีวิวร้านอาหารได้อย่างตรงจุด ทั้ง Lexicon-based Approach ที่ใช้พจนานุกรมเพื่อจำแนกอารมณ์เชิงบวกและเชิงลบ และ Machine Learning Approach ที่ใช้โมเดลอย่างเช่น Naive Bayes และ SVM ซึ่งสามารถช่วยเพิ่มความแม่นยำในการวิเคราะห์ความรู้สึก นอกจากนี้ การวิเคราะห์ในเชิงประเด็น (Aspect-based Analysis) ยังช่วยแยกแยะความคิดเห็นในแต่ละมิติ เช่น ความเห็นต่อคุณภาพอาหารหรือการบริการในรีวิวร้านอาหาร ช่วยให้เห็นภาพรวมของอารมณ์เชิงลึกในแต่ละด้าน

2.1.2 Sentiment Analysis of Financial News (2020) [6]

การวิเคราะห์ความรู้สึกในข่าวการเงินเป็นการศึกษาเกี่ยวกับการใช้เทคนิคการวิเคราะห์ข้อมูลเพื่อเข้าใจอารมณ์ที่แสดงออกในข่าว

การเก็บข้อมูล

ใช้ Finwiz เพื่อรวบรวมข่าวสารเกี่ยวกับหุ้นจากแหล่งข่าวที่เชื่อถือได้ เช่น Financial Times, Wall Street Journal, Bloomberg และ Yahoo Finance

วิธีการ

1. ใช้ VADER ผ่าน NLTK (Natural Language Toolkit)
2. ใช้ไฟล์ HTML เพื่อรวบรวมข้อมูล
3. สกัดข้อมูลจากเว็บเพจ โดยใช้ไลบรารี BeautifulSoup และจัดเรียงภายใต้หัวข้อต่าง ๆ ได้แก่ ตัวย่อหุ้น วันที่ เวลา และพาดหัวข่าว
4. ทำความสะอาดข้อมูล โดยการลบข้อมูลที่ซ้ำและข้อมูลในวันสุดสัปดาห์ที่ไม่มีการซื้อขายหุ้น
5. ใช้ไลบรารี VADER เพื่อกำหนดค่าความรู้สึก และเพิ่มคำสำคัญบางคำ เช่น crushes, beats, misses, trouble, falls พร้อมกับค่าความรู้สึกที่เหมาะสมลงในคลังคำศัพท์

6. สรุปและแสดงข้อมูลในรูปแบบกราฟิก โดยข้อมูลจะถูกจัดประเภทตามเปอร์เซ็นต์ของความรู้สึกเชิงบวก เชิงลบ และกลางในประโยค จากนั้นจะสร้างคะแนนผสม (compound score) โดยพิจารณาจากค่าผลรวมที่ปรับให้เป็นมาตรฐานของแต่ละประโยค

ความสอดคล้องกับงาน : นี้แสดงให้เห็นถึงการใช้เทคนิคการวิเคราะห์ความรู้สึกในข่าวการเงิน ซึ่งสอดคล้องกับการวิเคราะห์รีวิวร้านอาหารที่ต้องการทำความเข้าใจอารมณ์ในข้อความ โดยงานวิจัยนี้ใช้ VADER ผ่าน NLTK และไลบรารี Beautiful Soup สำหรับการสกัดข้อมูล ซึ่งสามารถนำมาปรับใช้ในโปรเจกต์นี้ได้ในการเตรียมและจัดการข้อมูลรีวิว นอกจากนี้ การปรับแต่งคลังคำศัพท์โดยเพิ่มคำที่มีความหมายเฉพาะเจาะจงและการสร้างคะแนนผสม (compound score) เป็นแนวทางที่สามารถนำมาปรับใช้ในการวิเคราะห์อารมณ์ในรีวิวร้านอาหารเพื่อให้ได้ผลลัพธ์ที่มีความแม่นยำและตอบโจทย์

2.1.3 Sentiment Analysis of Amazon Product Reviews Using Machine Learning and Deep Learning Models (2022) [7]

การวิเคราะห์ความรู้สึกจากรีวิวผลิตภัณฑ์ใน Amazon โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep Learning) เพื่อจำแนกประเภทความรู้สึกที่แสดงออกในข้อความรีวิว

ชุดข้อมูล

คะแนนและข้อความรีวิวของผลิตภัณฑ์ใน Amazon โดยใช้ชุดข้อมูลที่มีรีวิวจากผู้ซื้อ 34,000 รายการ

วิธีการศึกษา

- ใช้เทคนิคการเรียนรู้ของเครื่อง เช่น Linear Support Vector Machine, Random Forest, Multinomial Naïve Bayes, Bernoulli Naïve Bayes และ Logistic Regression
- ใช้ RNN (Recurrent Neural Network) ร่วมกับ LSTM (Long Short-Term Memory) เป็นวิธีการเรียนรู้เชิงลึก ซึ่งแสดงให้เห็นถึงความแม่นยำสูงสุดที่ 97.52%
- การประมวลผลข้อมูลรวมถึงการทำความสะอาดข้อมูล การลบคำที่ไม่สำคัญ (stop words) และการแปลงข้อความให้เป็นรูปแบบที่เหมาะสมสำหรับการวิเคราะห์

ผลลัพธ์

โมเดล Random Forest มีความแม่นยำ 91.90% ในขณะที่ RNN-LSTM แสดงถึงความแม่นยำสูงสุดที่ 97.52%

ความสอดคล้องกับงาน งานวิจัยนี้ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep Learning) ในการวิเคราะห์ความรู้สึกจากรีวิว ซึ่งสอดคล้องกับความต้องการในการ

จำแนกประเภทความรู้สึกของรีวิวร้านอาหาร นอกจากนี้ การประมวลผลข้อมูล เช่น การทำความสะอาด ลบคำไม่สำคัญ และการแปลงข้อความ ช่วยให้สามารถนำมาใช้ในโปรเจกต์นี้ได้ การใช้โมเดล RNN-LSTM ที่ให้ความแม่นยำสูงสุด (97.52%) เป็นแนวทางที่ดีสำหรับการวิเคราะห์รีวิวร้านอาหาร ซึ่งสามารถเพิ่มความแม่นยำและการตีความอารมณ์ในข้อความได้อย่างมีประสิทธิภาพ

2.1.4 Sentiment Analysis on Amazon Electronics Product Reviews using Machine Learning Techniques (2023) [8]

การวิเคราะห์ความรู้สึก บนชุดข้อมูลรีวิวผลิตภัณฑ์อิเล็กทรอนิกส์จาก Amazon โดยใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เพื่อเปรียบเทียบความแม่นยำของอัลกอริธึมต่าง ๆ โดยมีวัตถุประสงค์หลักเพื่อค้นหาอัลกอริธึมที่มีความแม่นยำสูงสุด

ชุดข้อมูล

รีวิวผลิตภัณฑ์จาก Amazon 20,000 รายการ โดยแบ่งเป็นรีวิวเชิงบวกและเชิงลบอย่างสมดุล
วิธีการ

- การทำความสะอาดข้อมูล: แยกรีวิวออกเป็นสองกลุ่มคือ เชิงบวกและเชิงลบตามคะแนนที่ให้
- การเตรียมข้อมูล: รวมถึงการขยายคำย่อ การลบอักขระพิเศษ การแบ่งคำ และการลบคำหยุด
- การสร้างพีเจอร์: ใช้เทคนิค Bag-of-Words (BoW) และ Term Frequency-Inverse Document Frequency (TF-IDF) เพื่อแปลงข้อความให้เป็นรูปแบบที่เหมาะสมสำหรับการสร้างแบบจำลอง
- การจำแนกประเภท: ใช้อัลกอริธึมต่าง ๆ เช่น Naive Bayes, Logistic Regression, Decision Tree, K-Nearest Neighbor, Random Forest และ Kernel Support Vector Machine รวมถึงโมเดลการเรียนรู้เชิงลึก เช่น Artificial Neural Network และ Recurrent Neural Network

ผลลัพธ์

Support Vector Machine (SVM) มีความแม่นยำสูงสุดที่ 94.02% ในการจำแนกประเภทรีวิว Naive Bayes ก็แสดงผลที่ดี โดยเฉพาะในบางกรณีที่มีความแม่นยำถึง 98.17% สำหรับรีวิวกล้อง [8]

ความสอดคล้องกับงาน งานวิจัยนี้ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เพื่อวิเคราะห์ความรู้สึกจากรีวิว โดยมีขั้นตอนการเตรียมข้อมูล ซึ่งสามารถนำมาปรับใช้กับการเตรียมข้อมูล รีวิวร้านอาหารในโปรเจกต์นี้ได้ นอกจากนี้ยังใช้วิธีการสร้างพีเจอร์ด้วย TF-IDF และ Bag-of-Words (BoW) ที่เหมาะสมสำหรับการแปลงข้อความในรีวิวอาหารให้อยู่ในรูปแบบที่โมเดลสามารถเรียนรู้ได้ และ การใช้โมเดลต่าง ๆ อย่างเช่น Naive Bayes, SVM, และ Recurrent Neural Network (RNN) ในการ

จำแนกประเภททรีวิว ซึ่งสอดคล้องกับความต้องการในการค้นหาโมเดลที่ให้ความแม่นยำสูงสุดในการวิเคราะห์ความรู้สึกจากทรีวิว

2.1.5 WANGCHANBERTA: PRETRAINING TRANSFORMER-BASED THAI LANGUAGE MODELS (2021) [3]

WangchanBERTa เป็นโมเดลการประมวลผลภาษาไทยที่ถูกพัฒนาขึ้นโดยสถาบันวิจัยปัญญาประดิษฐ์ประเทศไทย โดยมีวัตถุประสงค์เพื่อให้การประมวลผลภาษาธรรมชาติในภาษาไทยมีประสิทธิภาพสูงขึ้น โมเดลนี้ถูกฝึกฝนด้วยชุดข้อมูลขนาดใหญ่กว่า 78 GB และใช้เทคนิค Masked Language Model (MLM) ซึ่งเป็นวิธีการที่ช่วยให้โมเดลเรียนรู้การทำนายคำที่ถูกซ่อนอยู่ในประโยค โดยจะมีการแทนที่คำบางคำด้วย masked token และให้โมเดลทำนายคำที่ถูกแทนที่เหล่านั้น เทคนิคนี้ช่วยให้โมเดลเข้าใจบริบทของคำในประโยคได้ดีขึ้นโดยวัตถุประสงค์การพรีเทรน แทนที่ 15% ของโทเคนและแทนที่ด้วยโทเคน โดยใน 15% นั้น 80% จะถูกแทนที่ด้วยโทเคน, 10% จะไม่เปลี่ยนแปลงและ 10% จะถูกแทนที่ด้วยโทเคนแบบสุ่ม

ขั้นตอนการประมวลผลข้อมูล

1. การทำความสะอาดเบื้องต้น

- ลบ HTML
- ลบวงเล็บว่าง
- แทนที่การขึ้นบรรทัดใหม่ด้วยเว้นวรรค
- ลดจำนวนช่องว่างให้เหลือช่องว่างเดียว
- ลดจำนวนอักขระที่ซ้ำกัน (เช่น "ดีมากกก" → "ดีมาก")
- การแทนที่ช่องว่าง ด้วย < >

2. วิธีการแบ่งคำ

- SentencePiece tokenizer
- Word-level tokenizer
- Syllable-level tokenizer
- SEFR tokenizer

3. การแบ่งชุดการฝึก-การตรวจสอบ-การทดสอบ

- ชุดข้อมูล Assorted Thai Texts จำนวนคำต่อประโยค 5 ถึง 300 คำ (78.5 GB)

- ชุดข้อมูล Wikipedia เท่านั้น แบ่งชุดข้อมูลเป็น ฝึก/ทดสอบ/ทดสอบจริง โดยมี 944,782 ประโยคสำหรับการฝึก, 24,863 สำหรับการทดสอบ, และ 24,862 สำหรับการทดสอบจริง [3]

ความสอดคล้องกับงาน WangchanBERTa เป็นโมเดลภาษาไทยที่ถูกพัฒนาขึ้นโดยใช้เทคนิค Masked Language Model (MLM) เพื่อให้เข้าใจบริบทของภาษาไทยได้อย่างแม่นยำ ซึ่งสอดคล้องกับงานนี้ที่ต้องการใช้ WangchanBERTa ในการวิเคราะห์ความรู้สึกในรีวิวร้านอาหาร นอกจากนี้ งานนี้ยังมีขั้นตอนการเตรียมข้อมูลที่สำคัญ อย่างเช่น การลบ HTML การลดช่องว่างเกิน การลดตัวอักษรที่ซ้ำ และ การใช้ SentencePiece Tokenizer เพื่อแยกคำภาษาไทย ซึ่งสามารถนำมาปรับใช้ในการจัดการข้อมูล รีวิวร้านอาหารในงานนี้ได้เป็นอย่างดี

2.1.6 An Efficient Deep Learning for Thai Sentiment Analysis (2023) [9]

มุ่งเน้นการพัฒนาเทคนิคการวิเคราะห์อารมณ์สำหรับการจำแนกประเภทความรู้สึกในภาษาไทย โดยเฉพาะในโดเมนโรงแรม ซึ่งใช้วิธีการเรียนรู้เชิงลึกเพื่อเพิ่มประสิทธิภาพในการจำแนกประเภทความรู้สึก

แนวทางการดำเนินงาน

1. การสร้างเวกเตอร์
 - ใช้การฝังคำ (word embedding) โดยใช้เทคนิค Word2Vec
 - ใช้แนวทาง continuous bag-of-words (CBOW) และ skip-gram
 - ขนาดเวกเตอร์ 300 มิติ, n-gram ความยาว 5, ขนาดหน้าต่าง 5 และ 10
2. โมเดล Deep Learning
 - รวมการฝังคำกับโมเดล DL ได้แก่ CNN, LSTM, Bi-LSTM, GRU, Bi-GRU, CNN-LSTM, CNN-BiLSTM, CNN-GRU และ CNN-BiGRU
 - ทำการฝึกโมเดลกับ masked language modeling (MLM) และการทำนายประโยคถัดไป (NSP) โดยใช้ BERT
3. ข้อมูลและกระบวนการ
 - เลือกรีวิว 1,000 รายการจากชุดข้อมูลเพื่อติดฉลากเป็น 1 (แง่บวก) หรือ 0 (แง่ลบ)
 - ใช้เทคนิค TF-IDF เพื่อวัดความคล้ายคลึง
4. ค่าพารามิเตอร์สำหรับการฝึก
 - Word2Vec: มิติ 50, 100, 150, 200, 250, 300, ขนาดหน้าต่าง 2, Min_count 1

- CNN: จำนวนชั้น 3-5, units 8-128, ขนาด batch 128, อัตราการเรียนรู้ 0.0001, dropout 0.2, epochs 30

5. ผลลัพธ์

- โมเดล CNN ที่มี 4 ชั้น และ 64 units ได้ผลลัพธ์ดีที่สุดที่ 0.9146
- ใช้ embedding ขนาด 100 คำ
- โมเดล GRU และ CNN-GRU ได้ผลลัพธ์ดีเช่นกัน โดยความแม่นยำอยู่ที่ 0.9107 และ 0.9137 ตามลำดับ

6. การประเมินโมเดล

- ใช้ชุดข้อมูล 70% สำหรับการฝึก, 15% สำหรับการทดสอบ, และ 15% สำหรับการวัดประสิทธิภาพ
- ความแม่นยำสูงสุดจากโมเดล CNN ที่มีชั้นการคอนโวลูชัน 4 ชั้นและ 64 units ที่ 0.9170

7. การเปรียบเทียบโมเดล

- โมเดล CNN-BiLSTM ให้ความแม่นยำ 0.8485
- โมเดล CNN-GRU และ CNN-BiGRU มีความแม่นยำ 0.7992 และ 0.7793 ตามลำดับ

อุปกรณ์ที่ใช้

- GPU NVIDIA GeForce RTX 3060, CPU Intel(R) Core(TM) i9-9900 k, RAM 64 GB, Windows 10 Education

สรุป

- โมเดล CNN มีประสิทธิภาพดีที่สุดในการจัดประเภทความคิดเห็นในชุดข้อมูลโรงแรมไทย ด้วยความแม่นยำสูงสุด 0.9294, recall 0.9094, และ F1-score 0.9170[9]

ความสอดคล้องกับงาน ในงานนี้มีการพัฒนาเทคนิคการเรียนรู้เชิงลึกเพื่อเพิ่มประสิทธิภาพในการจำแนกอารมณ์ในภาษาไทย โดยเฉพาะในโดเมนรีวิวโรงแรม ซึ่งใกล้เคียงกับโดเมนร้านอาหารในงานที่เรา กำลังทำอยู่ มีการใช้เทคนิค word embedding เช่น Word2Vec ร่วมกับโมเดล CNN, LSTM และ GRU ที่ผสมกันหลากหลายรูปแบบ ช่วยให้โมเดลสามารถเรียนรู้ความสัมพันธ์ในเชิงอารมณ์ในระดับสูงได้ นอกจากนี้ การใช้ BERT สำหรับ masked language modeling (MLM) และการทำนายประโยคถัดไป (NSP) ช่วยเพิ่มความแม่นยำในการประมวลผลข้อความภาษาไทย

2.1.7 Fine-Tuning BERT for Sentiment Analysis of Vietnamese Reviews (2020) [10]

ได้ทำการทดลอง fine-tuning โมเดล BERT สำหรับการวิเคราะห์เชิงความรู้สึกในรีวิวภาษาเวียดนาม โดยใช้สองวิธีหลัก คือ 1) ใช้ [CLS] token ในการป้อนข้อมูลเข้าสู่โครงข่ายประสาทเทียม และ 2) ใช้ output ทั้งหมดจาก BERT ร่วมกับโมเดล LSTM, TextCNN, และ RCNN ผลการทดลองแสดงให้เห็นว่า BERT-RCNN ให้ผลลัพธ์ที่ดีที่สุดบนชุดข้อมูลทั้งสองชุด โดยในชุด Ntc-sv โมเดล BERT-RCNN มีค่า F1-score = 91.15% และในชุด Vreview ค่า F1-score = 88.22% เมื่อเปรียบเทียบกับโมเดลคลาสสิกอย่าง SVM และ XGBoost ที่ได้ F1-score ต่ำกว่า (90.84% และ 89.63% ในชุด Ntc-sv) และมีระยะเวลาในการเทรนที่น้อยกว่า สรุปได้ว่า BERT-RCNN เป็นวิธีที่ดีที่สุดสำหรับงานวิเคราะห์เชิงความรู้สึกนี้

ความสอดคล้องกับงาน : ในงานนี้มีการ fine-tuning โมเดล BERT ในภาษาเวียดนาม ซึ่งอาจจะเป็นวิธีการที่สามารถปรับใช้กับข้อความภาษาไทยได้ โดยในงานนี้จะกล่าวถึง 2 วิธีการด้วยกัน คือ การใช้ [CLS] token สำหรับการป้อนข้อมูลเข้าสู่โครงข่ายประสาทเทียม และการใช้ output ของ BERT ร่วมกับโมเดล LSTM, TextCNN, และ RCNN โดยโมเดล BERT-RCNN ให้ผลลัพธ์ที่ดีที่สุดด้วยค่า F1-score ที่สูงกว่ารุ่นโมเดลคลาสสิกอย่าง SVM และ XGBoost

2.1.8 Sentiment analysis of foreign tourists to Bangkok using data mining through online social network (2017) [11]

การวิเคราะห์ความรู้สึกของนักท่องเที่ยวต่างชาติที่เดินทางมายังกรุงเทพฯ โดยใช้การใช้ชุดข้อมูล 10,000 ชุด จาก Twitter โดยข้อมูลทั้งหมดได้ผ่านการได้ผ่านการแบ่งแยกคำ (tokenized) และการกรองข้อมูลก่อนนำไปวิเคราะห์ มีการใช้ Probabilistic Neural Network (PNN) และ Probabilistic Neural System (PNS) ในการค้นหารูปแบบที่ซ่อนอยู่ในข้อความ โดยได้ทำการทดลองการวิเคราะห์ความรู้สึกโดยใช้เทคนิคต่าง ๆ พบว่า Naive Bayes ให้ความแม่นยำ 55.66%, Decision Tree ให้ความแม่นยำ 79.83%, Support Vector Machine (SVM) ให้ความแม่นยำ 80.11% และ Artificial Neural Network (ANN) สามารถให้ผลลัพธ์ที่แม่นยำที่สุดที่ 80.33%

ความสอดคล้องกับงาน เป็นการวิเคราะห์ความคิดเห็นของข้อความภาษาไทยจากโซเชียลมีเดีย โดยในงานนี้จะใช้ข้อมูลจาก Twitter แต่ก็จะมีขั้นตอนการเตรียมข้อมูล อย่างเช่น การแบ่งแยกคำและการกรองข้อมูล ซึ่งเป็นขั้นตอนสำคัญที่สามารถนำมาปรับใช้กับงานนี้ได้เช่นกัน

2.1.9 Thai Sentiment Analysis and Visualization of Movie Reviews From Social Media (2022) [12]

การวิเคราะห์ความรู้สึกและการแสดงผลของรีวิวภาพยนตร์จากโซเชียลมีเดียในประเทศไทยเป็น การศึกษาเพื่อเข้าใจความคิดเห็นของผู้ชมเกี่ยวกับภาพยนตร์ไทย โดยโดยใช้อัลกอริทึม Naïve Bayes และ Support Vector Machine ในการวิเคราะห์ข้อมูล โพสต์จำนวน 4,000 โพสต์ ถูกจัดประเภทเป็น บวกหรือเป็นลบ โดยผลลัพธ์ของ Naïve Bayes มีค่า ความแม่นยำ อยู่ที่ 0.772 และ Support Vector Machine มีค่า ความแม่นยำ อยู่ที่ 0.755 และมีการใช้แบบสอบถามวัดความสามารถในการใช้งานของ ระบบ จากนักศึกษาปริญญาตรีจำนวน 30 คน ซึ่งแบ่งเป็นชาย 20 คน และหญิง 10 คน ผลลัพธ์แสดงให้เห็นว่า Naïve Bayes มีผลการทำงานดีกว่า Support Vector Machine เนื่องจากข้อความมีขนาดสั้น จึง ยากต่อการคำนวณ

ความสอดคล้องกับงาน : มีการใช้วิธีการวิเคราะห์ความคิดเห็นในข้อความภาษาไทยจากโซเชียล มีเดีย โดยอาศัยอัลกอริทึม Naïve Bayes และ Support Vector Machine ในการวิเคราะห์ข้อมูล ซึ่งทั้ง สองอัลกอริทึมนี้สามารถนำไปปรับใช้ในการวิเคราะห์ความรู้สึกในรีวิวร้านอาหารได้อย่างมีประสิทธิภาพ โดยเฉพาะในกรณีที่ข้อความรีวิวมีความยาวไม่มาก จะยังทำให้สามารถวิเคราะห์ได้แม่นยำยิ่งขึ้น

2.1.10 Thai Comments Sentiment Analysis on Social Networks with Deep Learning Approach (2019) [13]

การวิเคราะห์ความรู้สึกของความคิดเห็นในภาษาไทยบนโซเชียลมีเดียโดยใช้เทคนิคการเรียนรู้เชิง ลึก (Deep Learning) เป็นการศึกษาเพื่อเข้าใจความคิดเห็นของผู้ใช้เกี่ยวกับภาพยนตร์ โดยมีเอกสาร ทั้งหมด 41,073 ฉบับ โดยแบ่งเป็นเอกสารเชิงบวกจำนวน 21,490 ฉบับ และเอกสารเชิงลบจำนวน 19,583 ฉบับ โดยใช้สัดส่วนข้อมูลในการฝึกและทดสอบที่ 85:15 แต่ละคำในเอกสารจะถูกแทนด้วย เวกเตอร์ขนาด 300 มิติ และแต่ละเอกสารมีคำทั้งหมด 600 คำ

โดยมีวิธีการเตรียมข้อมูลดังนี้

1. ลบรูปแบบชื่อผู้ใช้ออก
2. กรองให้เหลือเฉพาะข้อความภาษาไทย
3. เปลี่ยน "555" เป็น "lol"
4. แก้ไขตัวสะกดสระที่ผิดพลาด
5. ลดตัวอักษรที่ซ้ำกัน

โดยเวกเตอร์คำที่ผ่านการฝึกมาก่อน: ใช้จากคลัง ULMFiT ภาษาไทยที่เป็นสาธารณะ
วิธีการที่ใช้:

- Long Short-Term Memory (LSTM)
- Gated Recurrent Unit (GRU)
- Recurrent Neural Network แบบสองทิศทาง (Bi-directional RNN)
- Attention Mechanism
- Convolutional Neural Network (CNN)

จากผลการทดลองพบว่าโมเดลที่ใช้ Bidirectional Gated Recurrent Unit (BGRU) และ Attention Mechanism (ATTN) มีค่า F-1 score สูงสุดอยู่ที่ 91.85

ความสอดคล้องกับงาน มีการใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) ที่สามารถช่วยวิเคราะห์ความคิดเห็นในข้อความภาษาไทยได้ค่อนข้างแม่นยำ และมีการใช้เทคนิคการเตรียมข้อมูลในรูปแบบต่าง ๆ ที่สามารถนำมาปรับใช้กับงานนี้เพื่อเพิ่มประสิทธิภาพของโมเดลได้ อย่างเช่น การแก้ไขตัวสะกดสระที่ผิดพลาด ซึ่งค่อนข้างเป็นเทคนิคที่น่าสนใจอย่างหนึ่งเลย เพราะเรามักพบกับสิ่งเหล่านี้ได้บ่อยครั้งกับการแสดงความคิดเห็นในแพลตฟอร์มออนไลน์ต่าง ๆ

2.1.11 Sentiment Analysis of Thai Stock Reviews Using Transformer Models(2022) [14]

การวิเคราะห์ความรู้สึกของรีวิวหุ้นไทยโดยใช้โมเดล Transformer เป็นการศึกษาเพื่อเข้าใจความคิดเห็นของนักลงทุนเกี่ยวกับหุ้นในตลาดหุ้นไทย โดยเป็น การวิเคราะห์ความรู้สึกแบบใช้พจนานุกรม (Lexicon-based Sentiment Analysis) โดยใช้ ข้อมูลของธนาคารกรุงศรีอยุธยาจำนวน 410 บทความ จากปี 2017 ถึง 2021 มีการเตรียมข้อมูลดังนี้:

1. การกรองข้อมูล: ลบตัวอักษรพิเศษออก
2. การเพิ่มข้อมูล: สลับย่อหน้าในบทความเพื่อเพิ่มจำนวนข้อมูลประเภทที่มีจำนวนน้อย

โมเดลและเครื่องมือที่ใช้:

- BERT-Base Tokenizer จาก Hugging Face แบ่งลำดับ Token IDs ให้มี 512 โทเคน ใช้โครงสร้าง 12 ชั้น จำนวนโหนดซ่อน 768 และ Multi-Head Attention 6 หัว
- WangchanBERTa Tokenizer มีความยาว 416 ตัว
- WangchanBERTa Model โครงสร้าง 12 ชั้น จำนวนโหนดซ่อน 768

- Tokenizer สำหรับ TF-IDF และใช้อัลกอริทึม TF-IDF กับ Logistic Regression โดยแบ่งชุดข้อมูลเป็นชุดฝึก (Train Set) 70% และชุดทดสอบ (Test Set) 30% ใช้จำนวนการทำซ้ำที่เหมาะสม 500 รอบ

ผลลัพธ์

โมเดล WangchanBERTa ที่ผ่านการฝึกมีความแม่นยำ 92.52%


โมเดล BERT แบบหลายภาษา (Multilingual BERT) และ TF-IDF มีความแม่นยำ 89.12% และ 85.03%[14]

ความสอดคล้องกับงาน: มีการใช้โมเดล Transformer อย่าง WangchanBERTa ในการวิเคราะห์ ซึ่งเป็นตัวเดียวกันกับตัวที่จะถูกนำมาใช้ในงานนี้ และมีขั้นตอนการเตรียมข้อมูลและเทคนิคต่าง ๆ อย่างเช่น การใช้ Tokenizer สำหรับการแยกคำ การกรองข้อมูลเพื่อลบตัวอักษรพิเศษ ที่เราสามารถนำมาปรับใช้กับการวิเคราะห์รีวิวร้านอาหารในงานนี้ได้

2.2 ความรู้พื้นฐาน เทคนิค เทคโนโลยีและเครื่องมือที่ใช้

2.2.1 พื้นฐานของ BERT และ Transformer

โมเดล Transformer ที่ถูกพัฒนาในปี 2017 โดย Vaswani et al. ในบทความ "Attention is All You Need" [15] ซึ่งนำเสนอเกี่ยวกับ โมเดลรูปแบบใหม่ ภายใต้ชื่อ Transformer โดยมีหัวใจสำคัญอยู่ที่กระบวนการที่เรียกว่า Self-Attention



รูปภาพที่ 2.1 Encoder-decoder model architecture


ที่มา: จาก chameleontk [16]

การแปลภาษาด้วยเครื่อง (Machine Translation) ไม่ได้เป็นเพียงกระบวนการจับคู่คำแปลแบบคำต่อคำเท่านั้น แต่ยังจำเป็นต้องเข้าใจความหมายในระดับประโยค และในบางกรณีอาจรวมถึงการตีความอารมณ์หรือเจตนาของผู้พูดด้วย ซึ่งทำให้กระบวนการนี้มีความซับซ้อนและท้าทายไม่น้อย

ในอดีต เทคนิคการแปลภาษาด้วยเครื่องอาศัยวิธีการเชิงสถิติล้วน (Statistical Machine Translation) ซึ่งสามารถให้ผลลัพธ์ในระดับเบื้องต้นได้ดี แต่ยังมีข้อจำกัดในเรื่องการเข้าใจลำดับคำและบริบทของข้อความอย่างแท้จริง

ต่อมาได้มีการพัฒนาโดยนำ Neural Networks มาใช้ โดยเฉพาะอย่างยิ่งโมเดลประเภท encoder-decoder หรือ sequence-to-sequence (seq2seq) ซึ่งมีหลักการพื้นฐานคือ การแปลงประโยคจากภาษาหนึ่งไปสู่อีกรูปแบบหนึ่งในอีกภาษา โดยที่ Encoder ทำหน้าที่ประมวลผลข้อความต้นฉบับและแปลงให้อยู่ในรูปของข้อมูลเชิงนามธรรม (intermediate representation) จากนั้น Decoder จะนำข้อมูลดังกล่าวไปสร้างเป็นประโยคใหม่ในภาษาปลายทาง ดังรูปภาพที่ 2.1

ข้อดีของแนวทางนี้คือ มีความยืดหยุ่นสูง สามารถประยุกต์ใช้งานกับงานด้านต่าง ๆ ได้โดยการปรับเปลี่ยนส่วนของ encoder หรือ decoder ให้เหมาะสมกับลักษณะข้อมูล เช่น การแปลงเสียงพูดเป็นข้อความ หรือการแปลข้อความจากภาษาหนึ่งไปยังอีกภาษา อย่างไรก็ตาม ในระยะเริ่มต้นของเทคนิคดังกล่าวยังคงพึ่งพาโครงข่ายประสาทเทียมแบบ RNN (Recurrent Neural Network) และ CNN (Convolutional Neural Network) เป็นหลัก ซึ่งถึงแม้จะมีข้อดีในด้านการจัดการกับลำดับข้อมูล แต่ก็ยังมีข้อจำกัดบางประการในเชิงประสิทธิภาพและความสามารถในการจดจำบริบทระยะยาว



รูปภาพที่ 2.2 ตัวอย่าง การประมวลผลของ RNN ซึ่งนำเข้าคำและข้อมูลจากคำก่อนหน้า ไปประมวลผล


ที่มา:จาก chameleontk [16]

Recurrent Neural Network (RNN) ได้รับความนิยมอย่างมากในช่วงแรกของการประยุกต์ใช้โมเดลปัญญาประดิษฐ์ในงานประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) เนื่องจากสามารถจัดการกับข้อมูลที่มีลำดับ (sequential data) ได้อย่างมีประสิทธิภาพ กล่าวคือ RNN มีความสามารถในการจดจำลำดับของคำในประโยค ซึ่งช่วยให้สามารถเข้าใจความหมายที่แตกต่างกัน เช่น ระหว่าง “แมวรักฉัน” กับ “ฉันรักแมว” ที่แม้จะประกอบด้วยคำเดียวกัน แต่การสลับลำดับคำทำให้ความหมายเปลี่ยนไปโดยสิ้นเชิง

หลักการทำงานของ RNN คือการประมวลผลข้อมูลที่ละคำ โดยผลลัพธ์จากคำก่อนหน้าจะถูกส่งต่อไปยังคำถัดไป คล้ายกับกระบวนการที่มนุษย์ค่อย ๆ อ่านประโยคจากซ้ายไปขวา ดังรูปภาพที่ 2.2 อย่างไรก็ตาม RNN มีข้อจำกัดสำคัญคือ ความสามารถในการจดจำข้อมูลที่อยู่ห่างกันในลำดับยาว (long-term dependencies) นั้นค่อนข้างต่ำ ตัวอย่างเช่น คำว่า “มัน” ที่ปรากฏในตอนท้ายของประโยคอาจมีความหมายโยงกับคำว่า “แมว” ที่ปรากฏในตอนต้นของประโยค ซึ่ง RNN อาจไม่สามารถรักษาความเชื่อมโยงนี้ไว้ได้


เพื่อลดข้อจำกัดดังกล่าว จึงมีการพัฒนาโมเดล RNN รุ่นใหม่ เช่น Long Short-Term Memory (LSTM) และ Gated Recurrent Unit (GRU) ซึ่งมีโครงสร้างภายในที่ออกแบบมาเพื่อให้สามารถ “เลือกจำ” หรือ “ลืม” ข้อมูลบางส่วนได้อย่างมีประสิทธิภาพ ส่งผลให้สามารถจัดการกับลำดับข้อมูลที่ยาวขึ้นได้ดีขึ้น อย่างไรก็ตาม โมเดลเหล่านี้ก็ยังมีข้อจำกัด โดยเฉพาะเมื่อต้องประมวลผลประโยคที่มีความยาวมาก

นอกจากนี้ เนื่องจาก RNN ทำงานในลักษณะเชิงลำดับ (sequential processing) โดยต้องประมวลผลคำก่อนหน้าก่อนจึงจะสามารถประมวลผลคำถัดไปได้ จึงทำให้ไม่สามารถประมวลผลแบบขนานได้ (non-parallelizable) ซึ่งเป็นอีกปัจจัยหนึ่งที่ทำให้โมเดลประเภทนี้มีข้อจำกัดด้านความเร็วในการประมวลผล



รูปภาพที่ 2.3 ตัวอย่าง หนึ่งหน่วยประมวลผลของ CNN ซึ่งนำเข้า กลุ่มคำ ไปประมวลผล

ที่มา:จาก P. Nakwijit [16]



รูปภาพที่ 2.4 ตัวอย่าง การส่งต่อข้อมูลใน CNN โดยยืงคำที่อยู่ใกล้กัน ยังต้องอาศัยหลาย layers กว่าโมเดลจะเจอข้อมูลของทั้งสองคำ

ที่มา:จาก P. Nakwijit [16]

Convolutional Neural Network (CNN) เป็นอีกหนึ่งรูปแบบของโครงข่ายประสาทเทียมที่ถูกนำมาประยุกต์ใช้ในงานประมวลผลภาษาธรรมชาติ โดยเฉพาะในงานที่เน้นการตรวจจับรูปแบบเฉพาะเจาะจงในระดับท้องถิ่น (local patterns) เช่น การจำแนกชื่อบุคคล ชื่อบริษัท หรือการตรวจจับวลีที่มีความหมายเฉพาะ

CNN แตกต่างจาก RNN ตรงที่ไม่ได้ให้ความสำคัญกับลำดับของคำมากนัก แต่จะพิจารณากลุ่มของคำที่อยู่ติดกันในประโยค เช่น “แมวสีส้ม” หรือ “ตัวอ้วนเดิน” แล้ววิเคราะห์ว่ากลุ่มคำเหล่านั้นมีรูปแบบที่น่าสนใจหรือไม่ โมเดลจะใช้ฟิลเตอร์ (filters) เลื่อนผ่านข้อความเพื่อดึงคุณลักษณะที่สำคัญออกมา ซึ่งเหมาะอย่างยิ่งสำหรับงานที่ต้องการระบุลักษณะหรือโครงสร้างที่มีขนาดเล็กภายในข้อมูล

ข้อได้เปรียบสำคัญของ CNN คือความสามารถในการประมวลผลแบบขนาน (parallel processing) เนื่องจากไม่ต้องรอข้อมูลจากคำก่อนหน้าเหมือนกับ RNN จึงสามารถทำงานได้รวดเร็วและมีประสิทธิภาพในเชิงคำนวณ อย่างไรก็ตาม ข้อจำกัดของ CNN คือ ขอบเขตการเรียนรู้จะจำกัดอยู่เพียงในบริเวณที่ฟิลเตอร์สามารถครอบคลุมได้ (receptive field) ซึ่งมักเป็นเพียงกลุ่มคำขนาดเล็ก ดังรูปภาพที่ 2.3 ส่งผลให้โมเดลมีข้อจำกัดในการเข้าใจบริบทที่ครอบคลุมทั้งประโยคหรือข้อความยาว ดังรูปภาพที่ 2.4

โดยสรุปแล้ว RNN มีความโดดเด่นในการประมวลผลข้อมูลตามลำดับ แต่มีข้อจำกัดในการจดจำความสัมพันธ์ระยะไกล ในขณะที่ CNN สามารถประมวลผลได้รวดเร็ว แต่มีข้อจำกัดในด้านความเข้าใจบริบทในระดับกว้าง ทั้งสองโมเดลจึงยังไม่สามารถตอบโจทย์ความต้องการของงานที่ซับซ้อนและต้องอาศัย ความเข้าใจบริบททั้งระบบได้อย่างสมบูรณ์ และนี่เองคือจุดเปลี่ยนสำคัญที่นำไปสู่การพัฒนาโมเดลประเภท Transformer ซึ่งได้เข้ามาเปลี่ยนแปลงแนวทางการประมวลผลภาษาธรรมชาติอย่างมีนัยสำคัญ



รูปภาพที่ 2.5 ตัวอย่างทำงาน

ที่มา: จาก K. Xu et al. [17]

Self-Attention ถือเป็นกลไกหลักและหัวใจสำคัญของโมเดลประเภท Transformer ซึ่งมีบทบาทในการช่วยให้โมเดลสามารถ “ให้ความสนใจ” กับคำที่มีความเกี่ยวข้องกันภายในประโยคได้อย่างมีประสิทธิภาพ ดังรูปภาพที่ 2.5 กล่าวคือ ในกระบวนการแปลความหมายของคำหนึ่ง ๆ โมเดลจำเป็นต้องพิจารณาว่าคำใดในประโยคมีอิทธิพลต่อการตีความคำนั้น เช่น ในประโยคที่มีคำว่า “ชอบ” โมเดลจำเป็นต้องอ้างอิงประธานของประโยค เช่น “เธอ” เพื่อเลือกคำกริยาให้ถูกต้องในภาษาอังกฤษระหว่าง *loves* กับ *love* ซึ่งไม่สามารถอาศัยแค่การพิจารณาคำแบบแยกเดี่ยวได้


กลไก Self-Attention ทำให้โมเดลสามารถระบุและให้ค่าน้ำหนักที่แตกต่างกันแก่คำต่าง ๆ ในประโยค โดยคำที่เกี่ยวข้องกันในเชิงความหมายจะได้รับมีความสำคัญมากกว่าคำที่ไม่เกี่ยวข้อง ส่งผลให้โมเดลมีความเข้าใจบริบทของภาษาได้ดีขึ้นอย่างมีนัยสำคัญ

นอกจากนี้ Self-Attention ยังมีข้อได้เปรียบเชิงเทคนิคที่สำคัญ คือสามารถประมวลผลแบบขนาน (parallel processing) ได้อย่างมีประสิทธิภาพ ซึ่งต่างจาก Recurrent Neural Network (RNN) ที่ต้องประมวลผลข้อมูลที่ลำดับ ส่งผลให้ Transformer ที่ใช้กลไก Self-Attention นั้นสามารถเรียนรู้และสร้างผลลัพธ์ได้ทั้งเร็วกว่าและแม่นยำกว่าในหลายกรณี

แม้ว่าการเชื่อมโยงทุกตำแหน่งคำเข้าด้วยกันผ่านโครงข่ายแบบ Fully-connected จะดูเหมือนเป็นทางเลือกหนึ่งที่สามารถเชื่อมโยงข้อมูลทั้งหมดได้โดยตรง แต่แนวทางดังกล่าวมักขาด “จุดโฟกัส” ในการตีความ ซึ่งทำให้โมเดลไม่สามารถตัดสินใจได้ว่าควรเริ่มต้นจากจุดใด หรือควรให้ความสำคัญกับคำใดเป็นพิเศษ เปรียบได้กับการอ่านบทความโดยไม่สามารถระบุประเด็นสำคัญได้อย่างชัดเจน


ด้วยเหตุนี้ กลไก Self-Attention จึงกลายเป็นองค์ประกอบที่พลิกโฉมวงการประมวลผลภาษาธรรมชาติ (Natural Language Processing) โดยช่วยให้โมเดลสามารถเข้าใจภาษาในระดับที่ลึกซึ้งและแม่นยำยิ่งขึ้นอย่างไม่เคยมีมาก่อน

2.2.1.1 Transformer Architecture



รูปภาพที่ 2.6 Transformer Architecture

ที่มา: จาก [18]



รูปภาพที่ 2.7 Input Embedding ของ Encoder


ที่มา: จาก P. Nakwijit [19]

จากภาพรวมของ Transformer Architecture ดังรูปภาพที่ 2.6 Input Embedding เป็นขั้นตอนเบื้องต้นก่อนที่จะนำข้อมูลเข้าสู่โมเดล Transformer โดยมีหน้าที่หลักคือการแปลงข้อความ(text)ให้อยู่ในรูปแบบเวกเตอร์เชิงตัวเลข (vector representations) ซึ่งเป็นรูปแบบข้อมูลที่โครงข่ายประสาทเทียม (Neural Networks) สามารถประมวลผลได้ ดังรูปภาพที่ 2.7 โดยเนื่องจากโมเดลเหล่านี้ไม่สามารถรับข้อมูลในรูปแบบของตัวอักษรได้โดยตรง

หนึ่งในเทคนิคที่นิยมใช้ในขั้นตอนนี้คือ Byte-Pair Encoding (BPE) ซึ่งเป็นวิธีการแยกคำออกเป็นหน่วยย่อยที่เรียกว่า subword units เทคนิคนี้มีข้อได้เปรียบในการจัดการกับคำที่ไม่เคยปรากฏมาก่อนในชุดข้อมูลฝึก (out-of-vocabulary words) เช่น คำว่า “unbelievability” ซึ่งอาจไม่อยู่ในพจนานุกรมของโมเดล จะถูกแยกออกเป็น subwords เช่น “un”, “believ”, “abil”, และ “ity” แทนที่จะแทนด้วยโทเคนพิเศษหรือข้ามไป ซึ่งช่วยให้โมเดลสามารถตีความความหมายบางส่วนของคำใหม่ได้แม้จะไม่เคยเห็นมาก่อน

หลังจากที่แบ่งคำเป็น subwords แล้ว แต่ละ subword จะถูกแมป (mapped) เข้ากับเวกเตอร์ผ่าน embedding lookup table ซึ่งในระยะแรกของการฝึกโมเดล เวกเตอร์เหล่านี้จะถูกสุ่มค่าเริ่มต้น (random initialization) และยังไม่สามารถสะท้อนความหมายหรือบริบทของคำได้อย่างถูกต้อง อย่างไรก็ตาม เมื่อผ่านกระบวนการฝึกด้วยข้อมูลขนาดใหญ่ เวกเตอร์เหล่านี้จะได้รับการปรับค่าจนสามารถสะท้อนถึงความหมาย ความคล้ายคลึง และความสัมพันธ์ระหว่างคำต่าง ๆ ได้อย่างแม่นยำ

ด้วยเหตุนี้ Input Embedding จึงเป็นขั้นตอนที่มีความสำคัญอย่างยิ่งต่อความสามารถของโมเดล Transformer ในการเข้าใจและประมวลผลภาษาธรรมชาติได้อย่างมีประสิทธิภาพ



รูปภาพที่ 2.8 สิ่งที่เกิดขึ้นใน Input Embedding เพื่อเปลี่ยนตัวอักษรเป็นเวกเตอร์ตัวเลข

ที่มา: จาก P. Nakwiji [19]

เนื่องจากโมเดล **Transformer** ไม่มีโครงสร้างภายในที่สามารถรับรู้ลำดับของคำในประโยคได้โดยตรง ต่างจากโมเดลประเภท Recurrent Neural Network (RNN) ที่ประมวลผลข้อมูลแบบเรียงลำดับ (sequential processing) จึงจำเป็นต้องมีการเพิ่มข้อมูลเกี่ยวกับลำดับตำแหน่งของคำเข้าไปในระบบ เพื่อให้โมเดลสามารถเข้าใจลำดับก่อน-หลังของคำในประโยคได้อย่างถูกต้อง

เทคนิคที่ใช้เพื่อวัตถุประสงค์นี้เรียกว่า **Positional Encoding** หรือ **Positional Embedding** โดยเป็นการสร้างเวกเตอร์แทนตำแหน่งของแต่ละคำในลำดับข้อความและนำมาบวกเข้ากับเวกเตอร์ของคำ (word embedding) ก่อนที่จะป้อนข้อมูลเข้าสู่โมเดล Transformer ดังรูปภาพที่ 2.8

หนึ่งในรูปแบบที่นิยมใช้คือการกำหนดค่าของ positional encoding โดยอิงตามฟังก์ชันตรีโกณมิติ คือ **sine** และ **cosine** ที่ความถี่ต่างกันในแต่ละมิติของเวกเตอร์ ดังรูปภาพที่ 2.9


$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}})$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$

รูปภาพที่ 2.9 ค่า $\sin/\cos$ ในการแทน position ต่าง ๆ

ที่มา: จาก A. Vaswani et al. [20]

การเข้ารหัสลักษณะนี้ทำให้โมเดลสามารถรับรู้ได้ว่าแต่ละคำอยู่ในตำแหน่งใดของประโยค เช่น การรู้ว่าคำว่า “แมว” ปรากฏก่อนหรือหลังคำว่า “กิน” ซึ่งเป็นข้อมูลที่มีความสำคัญอย่างยิ่งต่อการตีความความหมายของประโยคอย่างถูกต้อง



รูปภาพที่ 2.10 ภาพรวมของ Self-Attention


ที่มา: ดัดแปลงจาก [21] และ P. Nakwijit [19]

ภายหลังจากกระบวนการ Self-Attention ข้อมูลจะถูกส่งต่อเข้าสู่โมดูลย่อยที่เรียกว่า Feed-Forward Network (FFN) ซึ่งเป็นองค์ประกอบสำคัญอีกส่วนหนึ่งของโครงสร้างภายในโมเดล Transformer

FFN ทำหน้าที่ในการประมวลผลข้อมูลเพิ่มเติมภายหลังจากที่โมเดลได้พิจารณาความสัมพันธ์ระหว่างคำต่าง ๆ ผ่านกลไก Attention แล้ว โดยสามารถเปรียบได้กับชั้นการวิเคราะห์ภายในที่ช่วยเสริมความสามารถของโมเดลในการทำความเข้าใจบริบทเชิงลึกของแต่ละตำแหน่งคำ

โครงสร้างของ FFN มีลักษณะเป็น fully connected feed-forward neural network ที่มีสองชั้น (two-layer dense network) ประกอบด้วยฟังก์ชันการแปลงเชิงเส้นสองชั้น ซึ่งชั้นแรกจะขยายมิติของเวกเตอร์(expansion layer)และชั้นที่สองจะลดมิติกลับสู่ขนาดเดิม (compression layer) โดยมีการใช้ฟังก์ชันกระตุ้นแบบ ReLU (Rectified Linear Unit) ระหว่างชั้นเพื่อเพิ่มความไม่เป็นเชิงเส้น (non-linearity) ให้กับโมเดล ดังรูปภาพที่ 2.10

แม้ว่า FFN จะเป็นโครงสร้างที่ค่อนข้างเรียบง่ายเมื่อเทียบกับกลไก Attention แต่ก็มีความสำคัญอย่างยิ่งในการเสริมศักยภาพให้กับโมเดล Transformer โดยเฉพาะในแง่ของการเรียนรู้ลักษณะเชิงนามธรรม (abstract features) และการแยกแยะความหมายเชิงลึกของคำในบริบทต่าง ๆ ได้อย่างมีประสิทธิภาพ



รูปภาพที่ 2.11 ตัวอย่างการคำนวณ Attention เวกอร์ชั้นอย่างง่าย (no scaling and softmax)

ที่มา: จาก P. Nakwijit [19]

$$\text{softmax}(x_i) = \frac{\exp(x_i)}{\sum_j \exp(x_j)}$$

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T)V$$

$$\text{Attention}(K, Q, V) = \text{softmax}\left(\frac{KQ^T}{\sqrt{d_k}}\right)V$$

รูปภาพที่ 2.12 สมการการคำนวณ Attention

ที่มา: ดัดแปลงจาก P. Nakwijit [19]

หัวใจสำคัญของโมเดล Transformer คือกลไกที่เรียกว่า Self-Attention ซึ่งเป็นกลไกที่ช่วยให้โมเดลสามารถระบุได้ว่า คำใดในประโยคควรให้ความสำคัญมากที่สุดเมื่อประมวลผลคำหนึ่ง ๆ ตัวอย่างเช่น ในกรณีของคำว่า “ชอบ” โมเดลจำเป็นต้องพิจารณาว่า “ใคร” เป็นผู้กระทำ เพื่อให้สามารถตีความความหมายได้อย่างถูกต้อง

ในกระบวนการ Self-Attention ข้อมูลจากแต่ละตำแหน่งของลำดับคำจะถูกแปลงเป็นเวกเตอร์สามชุด ได้แก่ Query (Q), Key (K) และ Value (V) โดยเวกเตอร์ทั้งสามนี้ได้มาจากการนำเวกเตอร์ของแต่ละคำไปคูณกับเมทริกซ์ถ่วงน้ำหนักที่เรียนรู้ได้ (learnable parameters) คือ W_Q , W_K และ W_V ตามลำดับ


จากนั้นจะคำนวณ attention score ระหว่างแต่ละคู่ของคำโดยใช้ dot product ระหว่าง query และ key เพื่อวัดระดับความเกี่ยวข้อง (relevance) ระหว่างคำในประโยค ยกตัวอย่างเช่น หากคำนวณ dot product ระหว่าง query ของคำว่า “แมว” กับ key ของคำว่า “แมว”, “กิน” และ “ปลา” ได้ค่าเท่ากับ [10, 4, 6] ตามลำดับ ดังรูปภาพที่ 2.11 ระบบจะนำค่าดังกล่าวเข้าสู่ฟังก์ชัน Softmax เพื่อแปลงให้กลายเป็นเวกเตอร์ความน่าจะเป็น ซึ่งจะนำไปใช้เป็นน้ำหนักในการรวมเวกเตอร์ value ของแต่ละคำเข้าด้วยกัน โดยเวกเตอร์ผลลัพธ์จะเป็นการรวมข้อมูลจากคำที่ “เกี่ยวข้อง” มากที่สุดในบริบท ซึ่งช่วยให้โมเดลสามารถตีความความหมายของคำในบริบทนั้นได้ลึกซึ้งยิ่งขึ้น

ฟังก์ชัน Softmax มีบทบาทสำคัญในการแปลง attention score ให้กลายเป็นความน่าจะเป็นจริง (probability distribution) เนื่องจากค่าที่ได้จาก dot product โดยตรงนั้นมีลักษณะเป็น logits ซึ่งอาจมีขนาดใหญ่มาก โดยเฉพาะในกรณีที่ใช้เวกเตอร์ที่มีมิติสูง เช่น 512 มิติ ค่าจาก dot product อาจสูงถึงหลักพัน ส่งผลให้เมื่อผ่าน Softmax แล้ว โมเดลอาจให้ค่า

น้ำหนักสูงเกินไปกับบางตำแหน่ง และแทบไม่ให้น้ำหนักกับตำแหน่งอื่นเลย ซึ่งอาจทำให้เกิดการเรียนรู้แบบลำเอียงและไม่มีเสถียรภาพ

เพื่อลดผลกระทบจากค่าขนาดใหญ่ขึ้นี้ จึงมีการปรับขนาด (scaling) โดยหาร dot product ด้วย $\sqrt{d_k}$ ซึ่ง d_k คือมิติของเวกเตอร์ key (เช่น $\sqrt{512}$) เพื่อให้ค่าที่เข้าสู่ Softmax อยู่ในช่วงที่เหมาะสม ช่วยให้โมเดลมีการกระจายน้ำหนักที่เหมาะสมและสามารถเรียนรู้ได้อย่างมีประสิทธิภาพ ดังรูปภาพที่ 2.12

ด้วยกระบวนการทั้งหมดนี้ Self-Attention สามารถทำงานได้แบบขนาน (parallel computation) โดยไม่ต้องประมวลผลค่าแบบลำดับทีละค่าเหมือนโมเดล RNN ส่งผลให้ Transformer มีทั้งประสิทธิภาพในการประมวลผลและความสามารถในการเข้าใจความสัมพันธ์ภายในประโยคในระดับที่ลึกขึ้นอย่างมีนัยสำคัญ



รูปภาพที่ 2.13 ตัวอย่างสิ่งที่เกิดขึ้นใน Multi-head attention unit

ที่มา: จาก P. Nakwijit [19]

แม้กลไก Self-Attention จะมีความสามารถในการจับความสัมพันธ์ระหว่างคำในประโยคได้ดี แต่ในบางกรณี คำเพียงคำเดียวอาจมีความสัมพันธ์กับคำอื่นหลายกลุ่มพร้อมกัน ซึ่งการใช้ Self-Attention เพียงแบบเดียวอาจไม่เพียงพอในการเรียนรู้บริบทที่หลากหลาย ยกตัวอย่างเช่น ในประโยคภาษาอังกฤษว่า

"Bobby takes his cats to the park because they love climbing trees."

คำว่า "cats" มีความเกี่ยวข้องทั้งกับส่วนของประโยคที่ว่า "Bobby takes" และ "love climbing" รวมถึงอาจมีความสัมพันธ์เชิงนัยกับคำว่า "park" ผ่านความหมายของ "trees" ดังนั้นจึงจำเป็นต้องมีวิธีที่ช่วยให้โมเดลสามารถเรียนรู้ความสัมพันธ์ในหลายมิติพร้อมกัน

โมเดล Transformer จึงได้พัฒนาแนวทางแก้ไขด้วยกลไกที่เรียกว่า **Multi-Head Attention** ซึ่งทำงานโดยการสร้างชุด Self-Attention หลายชุด (heads) ให้ทำงานแบบขนานกัน โดยแต่ละชุดจะมีเมทริกซ์น้ำหนักของตนเอง ได้แก่ W_Q , W_K และ W_V ซึ่งแยกกันอย่างอิสระ ทำให้แต่ละหัวสามารถเรียนรู้ความสัมพันธ์ที่แตกต่างกันในประโยคเดียวกันได้

ผลลัพธ์จากแต่ละหัวจะถูกนำมาต่อกัน (concatenate) และส่งผ่านเมทริกซ์ถ่วงน้ำหนักอีกตัวหนึ่งคือ W_O เพื่อรวมข้อมูลทั้งหมดกลับมาเป็นเวกเตอร์ที่มีขนาดเท่าเดิม ดังรูปภาพที่ 2.13 ตัวอย่างเช่น 512 มิติ ในโมเดล Transformer มาตรฐานจะใช้ทั้งหมด 8 หัว โดยแต่ละหัวมีมิติขนาด 64 ซึ่งเมื่อรวมกันแล้วจะได้เวกเตอร์ขนาด 512 พอดี

ข้อดีของ Multi-Head Attention คือช่วยให้โมเดลสามารถพิจารณาความสัมพันธ์ได้หลายมุมมองภายในประโยคเดียวกันในการประมวลผลเพียงรอบเดียว ไม่จำเป็นต้องทำการประมวลผลซ้ำ ๆ ซึ่งส่งผลให้โมเดลสามารถเข้าใจข้อมูลได้อย่างลึกซึ้งและครอบคลุมยิ่งขึ้น

Layer Normalization ในสถาปัตยกรรม Transformer

แม้ว่าโครงสร้างพื้นฐานของ Transformer จะประกอบด้วยชั้น Attention และ Feed Forward Neural Network (FFN) เป็นหลัก แต่ในเชิงปฏิบัติแล้ว โครงสร้างย่อยแต่ละหน่วย (sublayer) ยังมีองค์ประกอบทางเทคนิคเพิ่มเติมที่สำคัญ ซึ่งหนึ่งในนั้นคือ Layer Normalization (LayerNorm)

Layer Normalization เป็นเทคนิคที่ช่วยเพิ่มความเสถียรและประสิทธิภาพในการเรียนรู้ของโมเดล โดยจะทำให้ค่าข้อมูลภายในแต่ละเลเยอร์มีค่าเฉลี่ยเท่ากับ 0 และความแปรปรวนเท่ากับ 1 เทคนิคนี้ดำเนินการกับข้อมูลของแต่ละตัวอย่างแยกกัน ต่างจาก Batch Normalization ที่อ้างอิงค่าจากทั้ง mini-batch ซึ่งทำให้ LayerNorm เหมาะสมกับงานที่ลำดับข้อมูลมีความยาวไม่แน่นอน เช่น งานประมวลผลภาษาธรรมชาติ (NLP)

ขั้นตอนของ Layer Normalization ประกอบด้วย:

1. คำนวณค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานของค่าทั้งหมดในเลเยอร์


2. ปรับข้อมูลให้อยู่ในรูปแบบ normalized (standardized)
3. คูณด้วยพารามิเตอร์สเกล และบวกด้วยพารามิเตอร์ออฟเซต เพื่อคงความยืดหยุ่นในการเรียนรู้ของโมเดล

ความจำเป็นในการใช้ Layer Normalization

การทำ Normalization มีบทบาทสำคัญในการลดปัญหา *internal covariate shift* ซึ่งคือการเปลี่ยนแปลงของ distribution ของข้อมูลภายในระหว่างการฝึกสอนโมเดล หากไม่จัดการปัญหานี้อย่างเหมาะสม อาจทำให้โมเดลเรียนรู้ได้ช้าลงหรือไม่เสถียร

ด้วยการ Normalize ข้อมูลในแต่ละชั้น โมเดลสามารถเรียนรู้ได้อย่างมีประสิทธิภาพมากขึ้น เนื่องจากช่วยให้ข้อมูลที่เข้าสู่แต่ละชั้นมีลักษณะเชิงสถิติที่คงที่ ส่งผลให้ชั้นต่าง ๆ ภายในโมเดลสามารถโฟกัสกับการประมวลผลของตนได้ดียิ่งขึ้น โดยไม่ถูกรบกวนจากการเปลี่ยนแปลงของข้อมูลที่มาจากรุ่นก่อนหน้า

กล่าวโดยสรุป Layer Normalization เปรียบเสมือนการสร้างขอบเขตที่ชัดเจนให้กับแต่ละชั้นของโมเดล ช่วยให้สามารถดำเนินการเรียนรู้ได้อย่างเป็นระบบและมีประสิทธิภาพยิ่งขึ้น



รูปภาพที่ 2.14 เส้นทางการทำ Residual connections

ที่มา: จาก He et al. [22]

นอกเหนือจาก Layer Normalization แล้ว สถาปัตยกรรมของ Transformer ยังประกอบด้วยองค์ประกอบสำคัญอีกสองประการ ได้แก่ Residual Connection และ Dropout ซึ่งล้วนมีบทบาทในการเพิ่มประสิทธิภาพและเสถียรภาพของการฝึกโมเดล

Residual Connection

Residual Connection หรือบางครั้งเรียกว่า *skip connection* เป็นเทคนิคที่ริเริ่มโดยสถาปัตยกรรม ResNet ซึ่งได้รับความนิยมอย่างแพร่หลายหลังจากชนะการแข่งขัน ImageNet ปี ค.ศ. 2015 จุดประสงค์หลักของเทคนิคนี้คือเพื่อแก้ปัญหา gradient vanishing ซึ่งมักเกิดขึ้นในโมเดลที่มีความลึกมาก ทำให้การส่งผ่านสัญญาณย้อนกลับเพื่ออัปเดตพารามิเตอร์ในช่วงฝึกสอนนั้นอ่อนกำลังลงเรื่อย ๆ

แนวคิดของ Residual Connection คือการเพิ่มทางลัด (shortcut) สำหรับส่งข้อมูลจากชั้นก่อนหน้า (input) ไปบวกเข้ากับผลลัพธ์ของชั้นถัดไปโดยตรง การกระทำนี้ทำให้สัญญาณสามารถส่งต่อได้อย่างมีประสิทธิภาพ ช่วยให้การเรียนรู้เชิงลึกเป็นไปได้ง่ายขึ้น ดังรูปภาพที่ 2.14

ใน Transformer เทคนิคนี้ถูกนำมาใช้ในทุก sublayer ไม่ว่าจะเป็น Self-Attention หรือ Feed Forward Neural Network โดยโมเดลจะนำผลลัพธ์จากแต่ละ sublayer มาบวกเข้ากับ input ดั้งเดิมของชั้นนั้นก่อนจะส่งต่อไปยัง Layer Normalization หรือขั้นตอนถัดไป วิธีการนี้ไม่เพียงช่วยลดปัญหาการสูญเสียข้อมูลต้นทางเท่านั้น แต่ยังส่งผลให้โมเดลสามารถเรียนรู้ได้เร็วขึ้นและมีความสามารถในการจดจำลำดับข้อมูลได้ดีขึ้นอีกด้วย

Dropout

Dropout เป็นอีกหนึ่งเทคนิคที่สำคัญในการฝึกสอนโมเดลเชิงลึก โดยทำหน้าที่ลดความเสี่ยงของการเกิด overfitting ระหว่างการฝึก ด้วยการสุ่ม "ปิด" หรือยกเลิกการทำงานของบาง neuron ชั่วคราวในแต่ละรอบของการอัปเดตพารามิเตอร์

แนวคิดเบื้องหลังของ Dropout คือการบังคับให้โมเดลไม่พึ่งพา neuron ใด neuron หนึ่งมากเกินไป ซึ่งช่วยให้โมเดลสามารถเรียนรู้คุณลักษณะของข้อมูลได้อย่างหลากหลายและยืดหยุ่นมากขึ้น

ในสถาปัตยกรรม Transformer การใช้ Dropout ถือเป็นเรื่องที่แพร่หลาย โดยจะถูกนำมาใช้ในหลากหลายส่วนของโมเดล เช่น:


- บน Input Embedding
- บน Positional Encoding

- ภายใน Multi-Head Attention
- ภายใน Feed Forward Neural Network
- และแม้กระทั่งก่อนการเชื่อมต่อ Residual
-

สรุปภาพรวมของ Encoder และ Decoder

Encoder ดังรูปภาพที่ 2.15 ประกอบไปด้วย

1. Input Embedding ซึ่งจะเอา BPE subwords เปลี่ยนให้เป็น Word Embedding แล้วบวกกับ Positional Embedding สร้างเป็น word vector ของแต่ละ subword
2. Word vector จะผ่านเข้าไปใน Encoder ซึ่งจะประกอบไปด้วย ชั้นของหน่วยย่อย ซ้อนกันเป็นชั้น ๆ ทั้งหมด 6 ชั้น แทนด้วย $N \times 6$
3. หน่วยย่อยแต่ละชั้น ประกอบไปด้วย Multi-head attention layer, LayerNorm, FFT และ Dropout




รูปภาพที่ 2.15 ส่วนประกอบใน Encoder

ที่มา: จาก P. Nakwiji [19]

Decoder ดังรูปภาพที่ 2.16 จะประกอบไปด้วย

1. Input Embedding เหมือนกับ Encoder (จริง ๆ แล้ว Encoder และ Decoder ใช้ lookup table อันเดียวกัน)

2. หลังจาก word vector จะผ่านเข้าไปใน Decoder ซึ่งจะประกอบไปด้วย ชั้นของหน่วยย่อยซ้อนกันเป็นชั้น ๆ ทั้งหมด 6 ชั้น แทนด้วย $N_x = 6$ เหมือนกับ Encoder
3. หน่วยย่อยแต่ละชั้น ประกอบไปด้วย Masked Attention layer, Encoder-decoder Attention layer, LayerNorm, FFT และ Dropout ตามรูปด้านล่าง สังเกตว่า มีเส้นสีแดงที่เป็น Output จาก Encoder เข้ามาด้วย



รูปภาพที่ 2.16 ส่วนประกอบใน Decoder

ที่มา: จาก P. Nakwiji [19]

หลังจากที่ข้อมูลได้ผ่านกระบวนการเข้ารหัส (Encoding) และถอดรหัส (Decoding) โดยส่วนของ Encoder และ Decoder แล้ว ขั้นตอนสุดท้ายในการสร้างผลลัพธ์ของโมเดล Transformer คือการแปลงเวกเตอร์เชิงความหมายให้อยู่ในรูปของคำ(tokens)ผ่านกระบวนการที่ประกอบด้วย Linear Transformation และ Softmax Function ดังรูปภาพที่ 2.17

Linear Layer


ผลลัพธ์จาก Decoder ที่อยู่ในรูปของเวกเตอร์เชิงความหมาย จะถูกส่งผ่านชั้นเชิงเส้น (Linear Layer) เพื่อแปลงเวกเตอร์เหล่านี้ให้อยู่ในขนาดที่สอดคล้องกับขนาดของคลังคำศัพท์ (vocabulary size) ในระบบ โดยทั่วไปน้ำหนักของ Linear Layer นี้จะถูกแชร์กับตาราง Lookup Table ที่ใช้ในขั้นตอน Input Embedding ซึ่งเป็นวิธีที่ช่วยลดจำนวนพารามิเตอร์ในโมเดลและยังช่วยให้เวกเตอร์ที่ได้มีความสอดคล้องกับเวกเตอร์ฝัง (embedding vector) ที่ใช้ในตอนต้น

Softmax Function

เวกเตอร์ที่ได้จาก Linear Layer จะถูกส่งผ่านฟังก์ชัน Softmax เพื่อแปลงเป็นเวกเตอร์ของค่าความน่าจะเป็น (probability vector) โดยที่แต่ละค่าจะแสดงถึงความน่าจะเป็นของคำศัพท์แต่ละคำในคลังคำศัพท์ว่าจะเป็นคำที่เหมาะสมที่สุดในตำแหน่งนั้นของลำดับผลลัพธ์

การเลือกคำจาก Probability Vector

จากเวกเตอร์ความน่าจะเป็นดังกล่าว โมเดลสามารถสร้างคำตอบได้โดยการ เลือกคำที่มีค่าความน่าจะเป็นสูงที่สุด (greedy decoding) หรือใช้วิธีสุ่มเลือก (sampling) ตามค่าความน่าจะเป็นที่ได้ ซึ่งจะช่วยเพิ่มความหลากหลายของผลลัพธ์ในกรณีที่ต้องการสร้างข้อความที่มีลักษณะเป็นธรรมชาติหรือไม่จำกัดรูปแบบตายตัว เช่น ในการประยุกต์ใช้งานด้านการสร้างบทสนทนา หรือการแปลภาษา




รูปภาพที่ 2.17 ภาพรวมของ Encoder และ Decoder

ที่มา: จาก P. Nakwijit [19]

2.2.1.2 BERT (Bidirectional Encoder Representations from Transformers) [23]

โครงสร้างของโมเดล BERT (Bidirectional Encoder Representations from Transformers) ได้รับการออกแบบโดยอิงจากสถาปัตยกรรมของ Transformer ดั้งเดิม แต่มีการปรับให้เหมาะสมกับงานที่เกี่ยวข้องกับการทำความเข้าใจภาษา (language understanding) โดยเลือกใช้เฉพาะส่วนของ Encoder ดังรูปภาพที่ 2.18 ซึ่งเพียงพอสำหรับการเรียนรู้และเข้าใจบริบทของข้อความในเชิงลึก แตกต่างจากโมเดลแปลภาษา (Machine Translation) จำเป็นต้องใช้ทั้ง Encoder และ Decoder ในการถอดรหัสภาษาหนึ่งไปสู่อีกภาษาหนึ่ง




รูปภาพที่ 2.18 Encoder ที่ BERT นำของ Transformers มาใช้

ที่มา: จาก P. Nakwijit [24]

BERT ถูกพัฒนาออกมาในสองเวอร์ชันหลัก ได้แก่ bert-base และ bert-large โดยมีความแตกต่างกันในแง่ของจำนวนเลเยอร์ (layers) และจำนวนพารามิเตอร์ ซึ่งเวอร์ชัน bert-large มีความลึกและซับซ้อนมากกว่า ส่งผลให้สามารถเรียนรู้ข้อมูลได้ละเอียดและแม่นยำยิ่งขึ้น

อีกจุดที่ BERT มีการปรับปรุงจาก Transformer ดั้งเดิม คือการเลือกใช้ ฟังก์ชันกระตุ้น (Activation Function) ที่แตกต่างกัน โดย BERT ใช้ GELU (Gaussian Error Linear Unit) แทน ReLU (Rectified Linear Unit) ซึ่งเป็นฟังก์ชันที่นิยมใช้ใน Transformer เดิม GELU มีข้อดีที่สามารถลดทอนค่าที่น้อยได้อย่างนุ่มนวล ไม่ตัดค่าให้เป็นศูนย์เหมือน ReLU ซึ่งช่วยให้การเรียนรู้ของโมเดลต่อเนื่องมากขึ้น และลดปัญหา neuron “ตาย” (dead neurons) ทำให้โมเดลสามารถฝึกฝนได้มีประสิทธิภาพยิ่งขึ้น



รูปภาพที่ 2.19 ภาพรวม ในแต่ละรอบของการสอน BERT


ที่มา: จาก P. Nakwijit [24]

กระบวนการ Pre-training ของแบบจำลอง BERT (Bidirectional Encoder Representations from Transformers) ประกอบด้วยการเรียนรู้จากสองภารกิจหลัก ได้แก่ **Masked Language Modeling (MLM)** และ **Next Sentence Prediction (NSP)** ดังรูปภาพที่ 2.19

ใน **Masked Language Modeling (MLM)** ระบบจะสุ่มเลือกคำประมาณร้อยละ 15 ของคำทั้งหมดในประโยคมาแทนที่ด้วยสัญลักษณ์พิเศษ [MASK] จากนั้นให้แบบจำลองพยายามทำนายคำที่ถูกแทนที่กลับมาให้ถูกต้อง โดยการดำเนินการในลักษณะนี้ส่งเสริมให้แบบจำลองเรียนรู้ความสัมพันธ์ระหว่างคำที่อยู่โดยรอบ และเข้าใจบริบทโดยรวมของข้อความได้ดีขึ้น

อย่างไรก็ตาม หากแทนที่คำที่ถูกสุ่มเลือกทั้งหมดด้วย [MASK] อาจส่งผลให้แบบจำลองเรียนรู้ที่จะพึ่งพาเพียงตำแหน่งของ [MASK] โดยไม่เข้าใจบริบทของคำอย่างแท้จริง ทีมวิจัยจึงได้เสนอเทคนิคที่เรียกว่า **Mixed Masking Strategy** โดยในคำที่ถูกสุ่มให้แทนที่นั้น จะถูกแทนด้วย [MASK] เพียงร้อยละ 80 ส่วนอีกร้อยละ 10 จะถูกแทนด้วยคำอื่นที่สุ่มขึ้นมา และอีกร้อยละ 10 จะไม่ถูกเปลี่ยนแปลงเลย เพื่อให้แบบจำลองสามารถเรียนรู้จากบริบทที่ใกล้เคียงกับการใช้งานจริงได้มากยิ่งขึ้น

ในส่วนของ **Next Sentence Prediction (NSP)** เป็นภารกิจที่มุ่งเน้นให้แบบจำลองเรียนรู้ความสัมพันธ์ระหว่างประโยค โดยโมเดลจะได้รับข้อความสองประโยค และต้องพิจารณาว่าประโยคที่สองเป็นประโยคที่ต่อเนื่องจากประโยคแรกในบทความเดียวกันหรือไม่ วิธีการนี้ช่วยส่งเสริมความสามารถของแบบจำลองในการเข้าใจลำดับและบริบทในระดับประโยค ซึ่งมีความสำคัญอย่างยิ่งในงานประมวลผลภาษาธรรมชาติประเภทต่าง ๆ เช่น การสรุปความ (summarization) และการตอบคำถาม (question answering) ดังรูปภาพที่ 2.20 แสดงโครงสร้างการทำงานของ BERT สำหรับโจทย์แบบ Multiple Choice โดยเปรียบเทียบคำถามกับตัวเลือกแต่ละข้อ แล้วเลือกคำตอบที่เหมาะสมที่สุด



รูปภาพที่ 2.20 ตัวอย่างการจัดการปัญหาของ BERT

ที่มา: จาก P. Nakwiji [24]

การนำ BERT ไปใช้งานหลังการ Pre-training

ภายหลังจากที่โมเดล BERT ได้ผ่านกระบวนการ Pre-training แล้ว ผู้ใช้งานสามารถนำโมเดลดังกล่าวไปประยุกต์ใช้งานต่อได้ใน 2 แนวทางหลัก ได้แก่ Fine-tuning และ Feature Extraction

Fine-tuning คือการนำโมเดล BERT ที่ผ่านการ Pre-train มาแล้ว มาทำการฝึกต่อเพิ่มเติมด้วยชุดข้อมูลเฉพาะของงานที่ต้องการ เช่น การวิเคราะห์ความรู้สึก (Sentiment Analysis) โดยจะมีการปรับเปลี่ยนเฉพาะส่วนของ classifier ที่อยู่ด้านบนสุดของโมเดล และทำการฝึกโมเดลใหม่เพียงไม่กี่รอบ (epochs) เพื่อให้สามารถเรียนรู้บริบทของข้อมูลเฉพาะงานนั้น ๆ ได้อย่างแม่นยำ ซึ่งแนวทางนี้เป็นที่นิยมอย่างแพร่หลาย เนื่องจากสามารถนำไปใช้งานได้ดียิ่งขึ้นและให้ผลลัพธ์ที่ดีมาก

Feature Extraction เป็นการใช้โมเดล BERT เพื่อดึงคุณลักษณะ (features) ของข้อความในรูปแบบเวกเตอร์ (embeddings) โดยไม่จำเป็นต้องปรับพารามิเตอร์ภายในของ BERT เพิ่มเติม จากนั้นนำเวกเตอร์ที่ได้ไปใช้ในโมเดลอื่น ๆ ที่กำหนดไว้ เช่น Logistic Regression หรือ SVM สำหรับการจำแนกข้อความ แนวทางนี้แม้จะไม่ผ่านการ Fine-tune กับข้อมูลใหม่โดยตรง แต่ก็ยังให้ผลลัพธ์ที่มีประสิทธิภาพสูงในหลากหลายงานประมวลผลภาษาธรรมชาติ

โดยภาพรวม BERT ถือเป็นจุดเริ่มต้นที่สำคัญของการเปลี่ยนผ่านเข้าสู่ยุคของ Pretrained Language Models ซึ่งส่งผลให้เกิดการพัฒนาโมเดลที่มีประสิทธิภาพสูงตามมาอีก

มากมาย ไม่ว่าจะเป็น RoBERTa, GPT-3, T5 และอื่น ๆ อีกมาก ซึ่งได้กลายเป็นแนวทางหลักในการพัฒนาเทคโนโลยีด้านภาษาธรรมชาติในปัจจุบัน

2.2.1.3 WangchanBERTa [25] เป็นแบบจำลองภาษาที่ได้รับการพัฒนาโดยทีมงานจากสถาบันปัญญาประดิษฐ์แห่งประเทศไทย โดยมีวัตถุประสงค์เพื่อรองรับการประมวลผลและทำความเข้าใจภาษาไทยโดยเฉพาะ แบบจำลองดังกล่าวพัฒนาต่อยอดจาก BERT (Bidirectional Encoder Representations from Transformers) ของ Google โดยยังคงโครงสร้างของ Encoder ในสถาปัตยกรรม Transformer ไว้เช่นเดิม

จุดเด่นของ WangchanBERTa คือการนำแนวทางการฝึกแบบ RoBERTa มาใช้ ซึ่งมีความแตกต่างจาก BERT ดั้งเดิมตรงที่ตัดขั้นตอน Next Sentence Prediction (NSP) ออกและใช้เพียง Masked Language Modeling (MLM) ส่งผลให้แบบจำลองสามารถเรียนรู้บริบทของคำได้ลึกซึ้งยิ่งขึ้น

ในกระบวนการฝึก ทีมพัฒนาใช้ชุดข้อมูลภาษาไทยที่รวบรวมจากหลากหลายแหล่ง อาทิ ข่าวสาร เว็บไซต์ วิกีพีเดีย และโพสต์จากสื่อสังคมออนไลน์ รวมปริมาณข้อมูลกว่า 78.5 กิกะไบต์ ซึ่งมีขนาดใหญ่กว่าชุดข้อมูลภาษาไทยที่ใช้ใน Multilingual BERT (mBERT) อย่างมีนัยสำคัญ

เนื่องจากภาษาไทยมีลักษณะเฉพาะด้านการตัดคำ ทีมวิจัยจึงได้ทดลองใช้เทคนิคการตัดคำหลายรูปแบบ เช่น SentencePiece, การจับคู่จากพจนานุกรม, การตัดคำตามพยางค์ และการตัดคำโดยใช้โมเดลเรียนรู้จากข้อมูล (ML-based Word Segmentation) ทั้งนี้เพื่อให้เวกเตอร์ที่ได้สะท้อนความหมายของคำในบริบทภาษาไทยได้อย่างแม่นยำ

สำหรับการฝึกโมเดล ได้ใช้เครื่อง Nvidia DGX-1 ที่ประกอบด้วย GPU Tesla V100 จำนวน 8 ตัว ทำการฝึกอย่างต่อเนื่องเป็นระยะเวลากว่า 125 วัน คิดเป็นจำนวนขั้นตอน (steps) ทั้งหมด 500,000 ขั้นตอน หรือประมาณ 5 รอบของชุดข้อมูลทั้งหมด

จากการทดลองปรับแต่งโมเดล (fine-tuning) กับชุดข้อมูลภาษาไทยหลายชุด พบว่า WangchanBERTa มีประสิทธิภาพสูง โดยเฉพาะในงานประมวลผลภาษาธรรมชาติที่เกี่ยวข้องกับการจำแนกประเภท (classification) เช่น การวิเคราะห์ความรู้สึก (sentiment analysis) และการรีวิว รวมถึงงานที่ต้องการวิเคราะห์ในระดับคำ (token-level) เช่น การระบุชื่อหน่วย

(Named Entity Recognition: NER) และการระบุชนิดของคำ (Part-of-Speech Tagging: POS)

จุดแข็งของ WangchanBERTa อยู่ที่ความสามารถในการทำความเข้าใจภาษาไทยในเชิงลึก ทั้งในระดับคำและระดับประโยค ทำให้สามารถนำไปประยุกต์ใช้กับงานเฉพาะทางด้านภาษาไทยได้อย่างมีประสิทธิภาพ นอกจากนี้ยังมีให้เลือกใช้งานในหลายเวอร์ชัน อาทิ เวอร์ชันที่ฝึกด้วยข้อมูลจากวิกิพีเดียเพียงอย่างเดียว หรือเวอร์ชันที่ฝึกจากข้อมูลบัพเต็ม 78.5 กิกะไบต์ ซึ่งสามารถเลือกใช้งานได้ตามลักษณะบริบทที่เหมาะสม

2.2.2 ทำงานของ BERT และการประยุกต์ใช้ในการ Sentiment Analysis

2.2.2.1 การประยุกต์ใช้ BERT ในการวิเคราะห์ความรู้สึก

โมเดล BERT ถูกใช้อย่างแพร่หลายในงานต่าง ๆ ที่เกี่ยวข้องกับการประมวลผลภาษาธรรมชาติ (NLP) รวมถึงงาน Sentiment Analysis ซึ่งเป็นการวิเคราะห์ความคิดเห็นจากข้อความ เช่น การทำนายระดับดาวจากข้อความรีวิว การฝึก BERT ด้วยข้อมูลรีวิวร้านอาหารจะช่วยให้โมเดลเข้าใจอารมณ์และความรู้สึกของผู้เขียนรีวิวได้อย่างแม่นยำ ไม่ว่าจะเป็นข้อความที่มีความหมายเชิงบวกหรือลบ

การใช้ BERT ในการทำ Sentiment Analysis ช่วยให้โมเดลสามารถเข้าใจความสัมพันธ์ของคำในประโยคและแยกแยะความคิดเห็นเชิงบวกหรือเชิงลบได้ดียิ่งขึ้น โดยการฝึกโมเดลให้สามารถทำนายคะแนนดาว (1-5 ดาว) จากข้อความรีวิวที่ได้รับ

2.2.3 เครื่องมือและเทคโนโลยีที่ใช้ในการพัฒนา

2.2.3.1 TypeScript และ Web Scraping

ในขั้นตอนการเก็บข้อมูลจากเว็บไซต์ Wongnai และ Google Maps เราใช้ TypeScript ในการพัฒนาโค้ดสำหรับ Web Scraping และการดึงข้อมูลจากหน้าเว็บไซต์ โดย TypeScript มีข้อดีในด้านการจัดการกับข้อมูล JSON ที่ได้จาก API และ HTML ที่ดึงมาได้อย่างมีประสิทธิภาพ

สำหรับ Google Maps, Selenium ถูกนำมาใช้ในการทำ Automation เพื่อเลื่อนหน้าเว็บและคลิกเพื่อดึงข้อมูลรีวิว เนื่องจาก Google Maps API มีข้อจำกัดในการดึงข้อมูลในปริมาณมาก Selenium WebDriver ช่วยให้สามารถควบคุมเบราว์เซอร์และเข้าถึงข้อมูลที่ต้องการได้

2.2.3.2 Hugging Face Transformers

เครื่องมือหลักที่ใช้ในการฝึก WangchanBERTa คือ Hugging Face Transformers ซึ่งเป็นไลบรารีที่รองรับการใช้งานโมเดลต่าง ๆ ในตระกูล Transformer เช่น BERT, GPT, RoBERTa, และ WangchanBERTa การใช้ Transformers ช่วยให้เราสามารถโหลดโมเดลที่ได้รับการฝึกไว้แล้วและทำการ Fine-tune ได้ง่ายและสะดวก

2.2.3.3 PyTorch และ TensorFlow

การฝึกโมเดล BERT ใช้ทั้ง PyTorch และ TensorFlow ซึ่งเป็นไลบรารีสำหรับการเรียนรู้เชิงลึก (Deep Learning) โดย PyTorch ได้รับความนิยมในการทำงานกับโมเดล Transformer มากที่สุดเนื่องจากความยืดหยุ่นในการพัฒนาและดีบั๊ก

2.2.4 การเก็บข้อมูลและการทำ Preprocessing

2.2.4.1 การเก็บข้อมูลจาก Wongnai และ Google Maps

ข้อมูลรีวิวจาก Wongnai และ Google Maps ถูกดึงออกมาโดยใช้ Web Scraping ผ่าน Selenium และ TypeScript โดยการเก็บข้อมูลที่เกี่ยวข้องกับร้านอาหารจากทั้งสองแหล่ง ทำให้ข้อมูลมีความหลากหลายและครอบคลุมจากแหล่งที่มีผู้ใช้จริง

2.2.4.2 การทำ Preprocessing ข้อมูล

การทำ Preprocessing ข้อมูลมีความสำคัญในการเตรียมข้อมูลให้พร้อมสำหรับการฝึกโมเดล เราใช้การลบ อีโมจิ, แฮชแท็ก, ตัวอักษรซ้ำ, และ ลิงก์ URL รวมถึงการจัดการ คำที่ติดกับตัวเลข และการ แปลงคำที่มีเครื่องหมาย + เป็นคำว่า "และ" เพื่อให้โมเดลสามารถเรียนรู้จากข้อมูลที่มีความหมายชัดเจน

2.2.5 การฝึกโมเดล (Training Process) และ Hyperparameter Tuning

2.2.5.1 การ Fine-tune โมเดล BERT

ในกระบวนการฝึกโมเดล BERT เราใช้ Hyperparameter Tuning เพื่อปรับค่าพารามิเตอร์ที่เหมาะสม เช่น Learning Rate, Batch Size, และ Epochs ซึ่งการเลือกค่าพารามิเตอร์เหล่านี้จะส่งผลโดยตรงต่อการเรียนรู้ของโมเดล การใช้ Hugging Face Trainer ทำให้การฝึกโมเดลนี้สามารถทำได้ง่ายและสะดวก

2.2.6 การประเมินผลโมเดล

2.2.6.1 การใช้ Metrics ในการประเมินผล

ในการประเมินผลของโมเดล Sentiment Analysis ที่ใช้ในการทำนายระดับดาวจากข้อความรีวิว, Metrics ที่ใช้ในการประเมินผลจะเป็นตัวชี้วัดที่สำคัญในการวัดประสิทธิภาพของโมเดล รวมถึงการวัดว่าโมเดลสามารถทำนายความคิดเห็นจากข้อความรีวิวได้แม่นยำแค่ไหน ซึ่งในที่นี้เราใช้ Accuracy, Precision, Recall, และ F1-Score เป็นตัวชี้วัดหลัก

- Accuracy คือ อัตราส่วนของการทำนายที่ถูกต้อง (True Positive + True Negative) ต่อจำนวนทั้งหมดของตัวอย่าง (True Positive + True Negative + False Positive + False Negative)
- Precision คือ อัตราส่วนของจำนวนการทำนายที่เป็นบวกที่ถูกต้อง (True Positive) กับจำนวนทั้งหมดที่โมเดลทำนายเป็นบวก (True Positive + False Positive) ซึ่งช่วยในการวัดว่าผลลัพธ์ที่โมเดลทำนายออกมานั้นมีความแม่นยำในการทำนายผลบวกแค่ไหน
- Recall หรือ Sensitivity คือ อัตราส่วนของจำนวนที่โมเดลทำนายเป็นบวกที่ถูกต้อง (True Positive) ต่อจำนวนทั้งหมดของตัวอย่างจริงที่เป็นบวก (True Positive + False Negative) ซึ่งช่วยในการวัดว่าโมเดลสามารถ ค้นหาทุกกรณีที่ควรเป็นบวก ได้ดีแค่ไหน
- F1-Score เป็นตัวชี้วัดที่รวม Precision และ Recall เข้าด้วยกันเพื่อให้ได้ค่าที่มีความสมดุลระหว่างทั้งสองค่าดังกล่าว ซึ่งมีความสำคัญโดยเฉพาะเมื่อข้อมูลที่ทำนายมีความไม่สมดุล (เช่น ข้อมูลรีวิวที่มีดาวต่ำไม่มากพอ) F1-Score จะช่วยให้เรามีค่าที่สะท้อนถึงประสิทธิภาพของโมเดลที่ดีขึ้น

2.2.7 การนำโมเดลไปใช้งานจริง

2.2.7.1 การใช้งาน Flask สำหรับการ Deploy โมเดล

Flask เป็น Web Framework สำหรับภาษา Python ที่ใช้ในการสร้างแอปพลิเคชันเว็บที่มีขนาดเล็กและเรียบง่าย โดยเหมาะสมสำหรับการสร้าง REST API ที่สามารถใช้ในการเชื่อมต่อกับ โมเดลที่ได้รับการฝึก เพื่อให้บริการต่าง ๆ ผ่านเว็บ

ในการพัฒนาโครงการนี้ Flask ถูกใช้ในการสร้าง API ที่ให้ผู้ใช้สามารถส่งข้อมูลข้อความรีวิวไปยังโมเดล เพื่อให้โมเดลทำการประเมินความรู้สึกจากข้อความดังกล่าวและส่งผลลัพธ์กลับมาในรูปแบบของ ระดับดาว (จาก 1 ถึง 5 ดาว) โดยกระบวนการทำงานหลัก ๆ มีดังนี้

- สร้าง API ด้วย Flask: ในการสร้าง REST API ผู้พัฒนาใช้ Flask เพื่อสร้างเส้นทาง (Routes) ที่รับข้อมูลจากผู้ใช้ เช่น ข้อความรีวิว โดยผ่าน HTTP Request เช่น POST ในการส่งข้อมูลที่ต้องการให้โมเดลประมวลผล และส่งผลลัพธ์กลับไปยังผู้ใช้
- การโหลดโมเดล: โมเดลที่ผ่านการฝึกเสร็จจะถูกโหลดเข้าสู่หน่วยความจำด้วยการใช้ไลบรารีที่รองรับ เช่น Hugging Face Transformers ซึ่งช่วยให้สามารถโหลดโมเดล WangchanBERTa หรือ BERT ได้อย่างง่ายดาย
- การทำนาย (Inference): เมื่อได้รับข้อความรีวิวจากผู้ใช้แล้ว ข้อความจะถูกแปลงเป็น Token โดยใช้ Tokenizer จากนั้นจะถูกป้อนเข้าโมเดลเพื่อการทำนายระดับดาว โดยผลลัพธ์ที่ได้จะถูกส่งกลับไปยังผู้ใช้ในรูปแบบ JSON

2.2.7.2 การ Deploy บน Render

หลังจากที่พัฒนาแอปพลิเคชันโดยใช้ Flask และ REST API ที่ทำงานร่วมกับโมเดลที่ฝึกเสร็จแล้ว ขั้นตอนถัดไปคือการ Deploy แอปพลิเคชันบน Render ซึ่งเป็นแพลตฟอร์ม Cloud Hosting ที่รองรับการรันแอปพลิเคชันที่พัฒนาโดยใช้ Python และ Flask เพื่อให้สามารถใช้งานได้จริงและให้บริการผู้ใช้งานจากที่ต่าง ๆ

Render เป็นแพลตฟอร์มที่สามารถทำการ Deploy แอปพลิเคชัน ฟรี และรองรับ Continuous Deployment ซึ่งหมายความว่าทุกครั้งที่มีการปรับปรุงโค้ดและ Push ไปยัง GitHub ระบบจะทำการ Deploy อัตโนมัติและทำให้แอปพลิเคชันสามารถใช้งานได้ทันที

บทที่ 3

อุปกรณ์และวิธีการ

3.1 เนื้อเรื่องย่อ

ในส่วนของโครงการนี้ จะเป็นการพัฒนาระบบ Sentiment Analysis (การวิเคราะห์ความรู้สึกจากข้อความ) ที่ถูก fine-tune จากโมเดลพื้นฐาน WangchanBERTa ด้วยข้อมูลความคิดเห็นหรือรีวิวเกี่ยวกับร้านอาหาร ในภาษาไทย โดยข้อมูลความคิดเห็นนี้ได้มาจาก 2 แหล่งด้วยกัน ได้แก่

- Wongnai
- Google Maps

เริ่มแรกข้อมูลที่นำมาใช้ฝึกโมเดลนั้น ได้มาจาก Wongnai ซึ่งเป็นแหล่งข้อมูลหลักที่รวบรวมความคิดเห็นรีวิวร้านอาหารจากผู้ใช้งานทั่วประเทศไทย โดยเฉพาะในวงการร้านอาหาร การเก็บข้อมูลจาก Wongnai ในช่วงเริ่มต้นพบว่ามีข้อมูลรีวิวจำนวนมาก แต่มีปัญหาด้านความไม่สมดุลของคลาส (class imbalance) โดยเฉพาะในระดับดาวต่ำ (1-2 ดาว) ซึ่งมีข้อมูลน้อยกว่าคลาสที่มีคะแนนสูง (3-5 ดาว) อย่างมาก เช่น ในข้อมูลที่เก็บจาก Wongnai พบว่า

- คลาส 1 ดาว: มีจำนวน 50 ตัวอย่าง
- คลาส 2 ดาว: มีจำนวน 70 ตัวอย่าง
- คลาส 3 ดาว: มีจำนวน 2,500 ตัวอย่าง
- คลาส 4 ดาว: มีจำนวน 2,200 ตัวอย่าง
- คลาส 5 ดาว: มีจำนวน 1,800 ตัวอย่าง

จากข้อมูลที่ได้มาในเบื้องต้น พบว่ามีความไม่สมดุลระหว่างคลาสต่าง ๆ โดยเฉพาะในกลุ่มคลาสดาวต่ำ (1 และ 2 ดาว) ที่มีตัวอย่างเพียงหลักสิบ ขณะที่คลาสดาวสูง (3, 4, 5 ดาว) มีจำนวนมากกว่าหลายเท่า จึงทำให้โมเดลที่ฝึกด้วยข้อมูลเหล่านี้อาจเกิดความเอนเอียง (bias) ไปในทางทำนายว่ารีวิวส่วนใหญ่เป็นความพึงพอใจสูง (ดาว 3-5) ซึ่งอาจไม่สะท้อนถึงความหลากหลายของความคิดเห็นที่มีอยู่ในโลกจริง

เพื่อแก้ไขปัญหานี้ จึงได้มีการไป เก็บข้อมูลเพิ่มเติมจาก Google Maps ซึ่งเป็นแหล่งรีวิวที่มีความหลากหลายและเป็นที่ยอมรับในกลุ่มผู้ใช้งานทั่วประเทศ โดยข้อมูลที่ได้จาก Google Maps จะถูกนำมาช่วย

บาลานซ์ (Balance) ข้อมูลที่ขาดหายไปในคลาส 1 และ 2 ดาว ในการรวบรวมข้อมูลจาก Google Maps นี้ จึงเน้นไปที่การเก็บข้อมูลรีวิวในกลุ่มดาวต่ำ เพื่อให้การกระจายของข้อมูลในแต่ละคลาสใกล้เคียงกันมากขึ้น จากการรวบรวมข้อมูลจาก Google Maps ได้มีข้อมูลรีวิวเพิ่มเติมดังนี้

- คลาส 1 ดาว: มีจำนวน 1,470 ตัวอย่าง
- คลาส 2 ดาว: มีจำนวน 1,370 ตัวอย่าง
- คลาส 3 ดาว: มีจำนวน 1,100 ตัวอย่าง
- คลาส 4 ดาว: มีจำนวน 1,200 ตัวอย่าง
- คลาส 5 ดาว: มีจำนวน 1,150 ตัวอย่าง

ดังนั้น หลังจากการรวบรวมข้อมูลจาก Wongnai และ Google Maps แล้ว ข้อมูลที่ได้จะมีจำนวนรวมทั้งหมด 7,200 ตัวอย่าง โดยมีการกระจายของข้อมูลในแต่ละคลาสอย่างสมดุล คลาสละ 1,440 ตัวอย่าง (สมดุลมากขึ้นหลังจากการเพิ่มข้อมูลจาก Google Maps) โดยสามารถแบ่งได้ตามแหล่งที่มาดังนี้

- คลาส 1 ดาว
 - Wongnai จำนวน 35 ตัวอย่าง
 - Google Maps จำนวน 1,405 ตัวอย่าง
- คลาส 2 ดาว
 - Wongnai จำนวน 62 ตัวอย่าง
 - Google Maps จำนวน 1,378 ตัวอย่าง
- คลาส 3 ดาว
 - Wongnai จำนวน 720 ตัวอย่าง
 - Google Maps จำนวน 720 ตัวอย่าง
- คลาส 4 ดาว
 - Wongnai จำนวน 600 ตัวอย่าง
 - Google Maps จำนวน 840 ตัวอย่าง
- คลาส 5 ดาว
 - Wongnai จำนวน 600 ตัวอย่าง
 - Google Maps จำนวน 840 ตัวอย่าง

ข้อมูลที่รวบรวมมาได้ทั้งหมดมีจำนวนทั้งสิ้น 7,200 แถว โดยแต่ละแถวประกอบด้วยข้อความรีวิว และระดับความพึงพอใจในรูปแบบของคะแนนดาว (ตั้งแต่ 1 ถึง 5 ดาว) เพื่อให้โมเดลสามารถเรียนรู้ได้

อย่างมีประสิทธิภาพ ได้มีการออกแบบชุดข้อมูลให้มี จำนวนตัวอย่างในแต่ละคลาสเท่ากัน เพื่อป้องกัน ปัญหาอคติ (bias) ระหว่างคลาส และได้แบ่งข้อมูลออกเป็นสองส่วนคือ ชุดฝึกโมเดล (Training set) จำนวน 6,000 แถว และ ชุดทดสอบโมเดล (Test set) อีก 1,200 แถว คิดเป็นอัตราส่วนการแบ่งข้อมูล 5:1

ก่อนที่จะนำข้อมูลเข้าสู่กระบวนการฝึกโมเดล ได้มีการดำเนินการ ทำความสะอาดข้อมูล (Preprocessing) อย่างละเอียด เพื่อให้มั่นใจว่าข้อมูลมีความเหมาะสมสำหรับการฝึก และไม่ก่อให้เกิด noise ที่อาจส่งผลกระทบต่อความแม่นยำของโมเดล โดยกระบวนการทำความสะอาดดังกล่าวประกอบด้วยการ ปรับเปลี่ยนและลบข้อความบางประเภทที่ไม่เกี่ยวข้อง หรืออาจรบกวนการเรียนรู้ของโมเดล โดยสรุปได้ ดังนี้

- ลบอีโมจิ ที่ปรากฏในข้อความ เช่น 😊, 🎉, 🚗 เป็นต้น เนื่องจากอีโมจิไม่ได้ให้ข้อมูลเชิง ภาษาที่สามารถวิเคราะห์ได้ตรง ๆ โดยโมเดลข้อความ
- ลบข้อความที่ลงท้ายด้วย ... ที่เกิดจากการลากเสียงหรือเน้นน้ำเสียง เช่น "อ..." จะถูกลบ ออกไปจนถึงช่องว่างถัดไป
- ลดจำนวนตัวอักษรที่ซ้ำกันเกินปกติ เช่น “มากกกก” ถูกแปลงเป็น “มาก” หรือ “เยียมมม” กลายเป็น “เยียม” เพื่อให้ภาษามีรูปแบบที่เป็นมาตรฐาน
- ลบแฮชแท็ก เช่น #WongnaiThaiSpecialist หรือ #อร่อยมาก ซึ่งเป็นสัญลักษณ์ที่ใช้บน แพลตฟอร์มโซเชียลแต่ไม่มีประโยชน์ต่อการเรียนรู้เชิงภาษา
- ลบข้อความแสดงเสียงหัวเราะ เช่น “555” หรือ “55555” ซึ่งพบได้บ่อยในภาษาไทยและ อาจรบกวนการเรียนรู้เชิงบริบทของโมเดล
- แทนที่เครื่องหมาย "+" ระหว่างคำด้วยคำว่า "และ" เช่น “ข้าว+แกง” จะแปลงเป็น “ข้าว และ แกง” เพื่อให้เป็นประโยคที่มีความหมายชัดเจน
- รักษารูปแบบของเวลา เช่น 8:30-15:00, 18:30 หรือ 18.30 โดยไม่มีการเปลี่ยนแปลงใด ๆ เพื่อให้เข้าใจเวลาได้ถูกต้อง
- แปลงช่วงตัวเลขที่มีเครื่องหมาย - เช่น “100-200” ให้เป็น “100 ถึง 200” เพื่อป้องกันความ คลุมเครือในการแยก Token
- เพิ่มช่องว่างก่อนและหลังตัวเลขที่ติดกับข้อความ เช่น “เสียใจทั้ง2ฝ่าย” → “เสียใจทั้ง 2 ฝ่าย” (ยกเว้นกรณีเวลา หรือสัดส่วน เช่น 18:30, 4/5 ซึ่งคงรูปไว้)

- รักษาข้อความที่มีเครื่องหมาย / เช่น “4/5”, “1/2” โดยไม่เปลี่ยนแปลง เพื่อคงความหมายดั้งเดิม
- ลบลิงก์ URL ที่ปรากฏในข้อความ เช่น <http://example.com> หรือ www.example.com ซึ่งไม่จำเป็นต่อการวิเคราะห์ความรู้สึก
- จัดการช่องว่างในข้อความ โดยลบช่องว่างที่ซ้ำกัน และจัดรูปแบบข้อความให้เป็นระเบียบ อ่านง่าย และเป็นมาตรฐาน

รวมไปถึงทำการเลือกเฉพาะข้อความแถวที่มีความยาวระหว่าง 80 – 510 ตัวอักษรเข้ามาใช้งาน เพื่อให้ไม่ได้ข้อความที่สั้นเกินไป หรือ ยาวเกินไปจนเกินขนาด Tokenizer มาใช้งาน

โมเดล WangchanBERTa ที่ถูกนำมาใช้ในงานนี้ ซึ่งเป็นโมเดลพื้นฐานมาจาก BERT ที่ได้รับการฝึกมาจากข้อมูลภาษาไทย จากข้อมูลหลายแหล่ง โดยหนึ่งในนั้นก็มีส่วนที่ใช้แหล่งข้อมูลจาก Wongnai เช่นเดียวกันซึ่งก็เป็นส่วนที่ทำให้โมเดลมีฟังก์ชันการทำงานแบบ Multiclass Classification จึงสามารถทำการจำแนกระดับดาวจากข้อความรีวิวได้ในระดับหนึ่งอยู่แล้ว แต่ก็ยังไม่ดีเท่าที่ควร จากการทดสอบด้วยข้อมูลชุดทดสอบ จำนวน 1200 แถว ในอัตราส่วนที่เท่ากันของทุกคลาส เพื่อทำการหาตัวโมเดลที่ดีที่สุดออกมาใช้งานจริง

และตัวอย่างข้อมูลจากที่ได้ผ่านการ Preprocessing แล้วดังตารางที่ 3.1 และ 3.2

ตารางที่ 3.1 ตารางแสดงตัวอย่างข้อมูลฝึกฝน

review_body	stars
อ่า ๆ ร้านค้าที่ไม่ขายเปียร์ท้องถิ่น ฤดูใบไม้ผลิแรก คุณไม่สามารถสั่งอาหารราคาถูกหรืออาหารที่ต้องใช้เวลาได้ ฉันมาที่นี่เมื่อ 9 ปีที่แล้ว และรู้สึกแปลก ๆ มาก เรามาทัวร์กันเป็นหมู่คณะ Caoli ตั้งใจมากจนดูเหมือนเป็นร้านอาหารที่พวกเขาร่วมมือกับไกด์ ดู? ดูพระอาทิตย์ตกที่เกาะ Wolmi แล้วตัดสินใจว่าจะดีหรือไม่ อย่างไรก็ตาม รสชาติก็จืด ๆ และไม่มีพนักงานคอยถามทัก เลยให้คนละ 2 ดาว	1
ทานแล้ว อาหารเป็นพิษ คับ พนักงานบริการไม่ดีเท่าที่ควร โดยเฉพาะน้องผู้หญิงที่โพนมค์หน้าร้าน	1
1. ห้ามดื่มแก้วไวน์ 2. หากต้องการชำระด้วยบัตรเครดิต บิล 335 บาท จะกลายเป็น 500 3. รุนแรงมากเสียงดัง พนักงานเสิร์ฟเร่งรีบ คนจีนพูดเสียงดัง 4. วิวที่นี้ไม่สวยอย่างที่คิด แคน้ำสกปรก - โปรดทราบว่าร้านอาหารมีขนาดใหญ่มาก! ไม่ใช่สำหรับหนึ่งร้อยคน ที่นี้ไม่มีบรรยากาศที่ผ่อนคลาย ฉันสังเกตว่าถ้าคุณขอเผ็ดอาหารจะเผ็ดมากจริง ๆ สำหรับฉันมันก็เหมือนกัน แต่ปากของใครบางคนอาจจะไหม้	2
มาดัมตั้มยำ ยาแหลมอน เนื้อเป็ด มูคัพ และมูมาเนา อร่อยทุกอย่าง แต่ฉันเป็นโรคลำไส้อักเสบ มันอร่อยแต่ระวังถ้าคุณเป็นโรคลำไส้อักเสบด้วย	2

อาจเพราะว่าปัจจุบันไม่มีนักท่องเที่ยวชาวจีน เราจึงทานอาหารในบรรยากาศที่เงียบสงบพร้อมลมทะเลเย็น ๆ ปริมาณอาหารน้อยเมื่อเทียบกับราคาจึงไม่ถูกและอาหารโดยทั่วไปก็อร่อย ถ้าคุณชอบอาหารทะเลคุณอาจต้องการไปเยี่ยมชมอย่างน้อยหนึ่งครั้ง	3
"ร้านอาหารที่มีวิวทุ่งนา ใช้อาคารไม้เก่า ที่เรียกว่า ""หลองข้าว"" มาดัดแปลงเป็นที่ให้คนมานั่งกินทางเดินไม้บ้าง สะพานบ้าง ไปแต่ละส่วน ๆ มีน้ำ มีการออกแบบแลนด์สเคปให้ร่มรื่น สวยงาม สำหรับอาหาร เป็นอาคารไทย มีเมนูเอกลักษณ์คือข้าวพันธ์ต่าง ๆ หลากสี ส่วนตัวเมนูอาหารส่วนใหญ่เฉย ๆ ให้คะแนนกับบรรยากาศเป็นหลัก"	3
ทุกเมนูใช้ได้หมด หมูกรอบอร่อยมากและมันมากไม่แห้งจนเกินไป กุ้งจิ้ม เกาเหลา รสชาติดี บริการก็ดี แต่บะหมี่แห้งเส้นเค็มไปนิด ตี๋ฮวนผักกาดดองก็เปรี้ยวไปหน่อยต้องเติมน้ำร้อน แนะนำว่าอย่าใส่น้ำปลาเพิ่ม คนกินเยอะ ร้านแคบไปนิด บางทีก็สกปรกแต่โดยรวมแนะนำค่ะ ร้านนี้ชอบนั่งกินคนเดียวไม่เบียด	4
วันนี้ต้องมาห่างแต่เช้า ย่านสุขุมวิท ทองหล่อ เอกมัย อยากหาอะไรกินแบบง่าย ๆ นอกห้าง ต้องที่นี้ละ ร้านแซว เต๋ยวแคะ ที่นี้ทำก๋วยเต๋ยวเส้นบาง ๆ (เส้นใหญ่) รสชาติไปได้ ย่านนี้หากินแบบนี้ยากแล้วครับ หรือดึก ๆ ไม่เกิน 4 ทุ่มก็ยังหากินได้อยู่ อยากบิ๊ง ผรั่งมั่งค่าก็มีมากินกันเยอะ	4
เนื้อปูผัดพริกเหลือง เนื้อกรรเชียงเป็นก้อนเต็ม ๆ คำ ทานกับข้าวสวยร้อน ๆ ดึงามมากคะ แกงส้มไหลบัวกุ้งแม่น้ำ อร่อยมาก ๆ ค่ะตบท้ายด้วยไอศกรีมมะพร้าว น้ำหอม ชื่นใจมากเลย	5
มาหลายรอบแล้ว เมนูหลากหลาย เด็กชอบไข่กวน. แต่ผู้ใหญ่ชอบ มัสมั่นไก่ สดุ้งคั่วหมู. อาหารไทยแท้ผสมทางเหนือนิด ๆ จอดร่ง่าย. ราคากลาง ๆ รับผิดชอบ	5

ตารางที่ 1.2 ตารางแสดงตัวอย่างข้อมูลชุดทดสอบ

review_body	stars
ผิดหวังกับสถานที่เพราะเป็นสถานที่สร้างอาหารจริง ๆ สถานที่ที่ท่งเทียวน้อยและจุดถ่ายรูปไม่ดี ร้านอาหารมีอยู่ทั่วทุกแห่ง สถานที่ที่ซื้อซ็อกโกแลตวิลล์แต่เราไม่พบร้านหรือจุดพิเศษที่เกี่ยวข้องกับ ซ็อกโกแลตเลย นักท่องเที่ยวต้องเสียค่าธรรมเนียมแรกเข้า สรุปล่มคนสร้างเพื่อเอากำไรจากนักท่องเที่ยว	1
ที่จอดรถน้อยมากไม่ดีเลย ร้านค่อนข้างมืดมาก อึดอัดมาก รสชาติห่วยไม่อร่อย แต่ใส่แอมป์หมื่นมาก ให้ พนักงานบริการแย่มากไม่ชอบแอมป์มากไม่ประทับใจ	1
อาหารรสออกหวาน สั่งข้าวเป็นโถก็ไม่มีฝาปิด แกงส์ตอนมาเสิร์ฟเย็นมาเลยต้องจุดแอลกอฮอล์อุ่น 2 รอบถึงจะร้อน	2
รสชาติอาหารกลาง ๆ การบริการไม่คุ้มกับเซอร์วิสชาร์จ 10 % เพราะเข้ามาไม่มีพนักงานมาบริการ หา โต๊ะนั่งด้วยตนเอง ไปเอาเมนูมาดูเอง และคิดบิลผิด ควรตรวจบิลดูก่อนชำระเงิน ส่วนพนักงานรับรถ บริการดี บรรยากาศเห็นสะพานเห็นแม่น้ำ และมีที่จอดรถ	2
สถาปัตย์ดีดีกระเทียมรสชาติพอใช้ได้ เนื้อย่างไม้ก็ทานได้อยู่ สังกาแฟมาลอง รสชาติค่อนข้างอ่อน แต่ก็ยัง พอทานได้ครับ	3
เคยไปทานกับเพื่อนเมื่อปีก่อน ครึ่งนี้กลับไปอีกครั้ง รู้สึกว่าเนื้อหมูและไก่ที่ให้นำน้อยกว่าที่คาด โดยเฉพาะ เนื้อวัวแบบพิเศษที่ได้ปริมาณน้อยและเนื้อค่อนข้างเหนียว เบคอนทอดมีรสชาติโอเค ข้าวผัดกะเพราและ เล็กน้อย รสชาติพอใช้ได้ สุกี่แห่งที่เพื่อนสั่งรสชาติดี	3
ผ่านมาเลยวะทานดู บรรยากาศดีดีดีทะเล มีถนนส่วนตัวคัน ที่จอดรถไม่มีร่มเงา ต้องให้ทิปผ้าคลุมรถ อาหารอร่อยดีใช้ได้ ราคาไม่แพงนัก เสริฟเร็ว ข้าวอบทะเลกระหรี่ปริมาณมาก ปลากระพงทอดน้ำปลา ที่ จอดรถดี	4
มาวันธรรมดาช่วงกลางวันอากาศโอเค ชอบต้มเลือดหมูอร่อย เมนูต้มยำรายการเยอะ รสชาติดีค่ะ โดยรวม พอใจดีค่ะ	4
แยกโซนคาเฟ่ กับโซนอาหาร แต่สามารถสั่งมาทานด้วยกันได้ อาหารอร่อยมาก บรรยากาศดี วิวหลักล้าน ราคาเหมาะสม พนักงานน่ารักทุกคนบริการดี	5
วันนี้แวะมากินอาหารร้านแม่เจริญ ภายในร้านสะอาดแอร์เย็นสบาย พนักงานบริการดี ได้ลองสั่งเย็นตาโฟ หม้อไฟที่เขาแนะนำ แล้วก็หมีกกระทายัดมันน้ำดำเห็นบอกว่านาน ๆ จะมีมาที่ มีทอดมันปูที่แนะนำ ของ สดใหม่และอร่อยทุกอย่างเลย หน้าร้านก็มีของฝากกลับบ้านด้วย มื้อนี้อร่อยแล้วก็มีความสุขมากอิมสุด ๆ ไว้โอกาสหน้ามาอีกแน่นอน	5

3.2 รายละเอียดวิธีการ

ในส่วนของวิธีการจะแบ่งออกได้เป็น 3 ขั้นตอนหลัก ๆ ดังนี้

3.2.1 การจัดเตรียมชุดข้อมูล (Dataset Preparation)

จากที่กล่าวไว้ข้างต้นว่าจะมีการนำข้อมูลจาก 2 แหล่ง คือ Wongnai และ Google Maps ซึ่งเป็นแพลตฟอร์มที่มีข้อมูลร้านอาหารจำนวนมาก และมีผู้ใช้งานในประเทศไทยอย่างแพร่หลาย เพื่อนำมาใช้ฝึกและทดสอบโมเดล โดยจะมีแนวทาง หรือ วิธีการที่ใช้ดังนี้

3.2.1.1 Wongnai

ตัวเว็บไซต์เคยเปิดให้บริการ API แต่ด้วยเหตุผลบางประการ ปัจจุบันไม่มี API ให้ใช้บริการแล้ว จึงจะต้องใช้วิธีการดึงข้อมูลจาก HTML หรือที่เรียกว่า Web Scraping เข้ามาช่วย โดยได้เลือกใช้ ภาษา TypeScript ในการพัฒนา ขั้นตอนหลัก ๆ และสิ่งที่ต้องการสำหรับการเข้าไปเก็บข้อมูล คือ ไอดีเฉพาะของร้านอาหารนั้น ๆ โดยจะสามารถหาได้จากส่วนท้ายของลิงค์ Wongnai.com เพื่อนำมาใช้เป็นพารามิเตอร์ของฟังก์ชันในการส่ง HTTP Request (GET) ไปยัง Endpoint ที่กำหนด จากนั้นจะได้ข้อมูลกลับมาเป็นรูปแบบ json ของหน้าเว็บไซต์ ขั้นตอนต่อมาที่ทำ คือ นำข้อมูลนั้นมาทำการจัดเรียงอีกครั้ง เพื่อให้ได้ในส่วนของคุณสมบัติที่เราต้องการนั่นคือ ข้อความรีวิว และ ระดับดาว

3.2.1.2 Google Maps

ในส่วนของเว็บไซต์นี้ มีบริการ API ของ Google Cloud Console เปิดให้ใช้บริการ แต่เนื่องด้วยตัว API เองมีการจำกัดการส่งกลับข้อมูลมาแค่ครั้งละ 5 แถว ต่อ 1 คำขอ ซึ่งไม่เพียงพอต่อการนำมาใช้งาน จึงได้ทำคล้ายวิธีการแบบ Wongnai แต่ใช้วิธี Automation ผ่าน Selenium ซึ่งเป็นเครื่องมือสำหรับการควบคุมเบราว์เซอร์โดยอัตโนมัติ ขั้นตอนหลัก ๆ และสิ่งที่ต้องการสำหรับการเข้าไปเก็บข้อมูล คือ ลิงค์สถานที่ที่ต้องการจะดึงข้อมูลรีวิวและพาร์ทของข้อมูลส่วนต่าง ๆ ที่เราต้องการจากเว็บไซต์นั้น ๆ เมื่อข้อมูลครบแล้วและโปรแกรมเริ่มทำงาน ตัวโปรแกรมก็จะเข้าไปยังลิงค์สถานที่ หรือ ร้านอาหารที่เราป้อนเข้าไป แล้วทำการ Scroll Down ลงไปเรื่อย ๆ ตามจำนวนรอบที่เรากำหนด เพื่อให้ได้ข้อมูลในจำนวนที่มากขึ้น แต่ก็ใช้เวลาารอนานเช่นเดียวกัน หลังจากนั้นเราก็จะได้ส่วนของข้อมูลที่เราต้องการนั่นคือ ข้อความรีวิว และ ระดับดาว

หลังจากที่ได้ข้อมูลจากทั้ง 2 แหล่งที่กล่าวถึงนี้มาแล้ว จะต้องนำไปผ่านกระบวนการคัดกรองข้อมูล เพื่อให้ได้ข้อมูลที่มีประสิทธิภาพมากที่ในการนำไปใช้ฝึกและทดสอบโมเดลอีกในขั้นตอนต่อไป โดยกระบวนการนี้จะประกอบด้วย การกรองสิ่งที่ไม่เกี่ยวข้องและแก้ไขสิ่งที่ผิดพลาดออกไป ยกตัวอย่างเช่น “อรรอยมากกกก” -> “อรรอยมาก” เป็นต้น รวมไปถึงลบข้อความรวิบบางแถวที่มีความยาวของข้อความที่ไม่เหมาะสม อย่างในโครงการนี้ จะเลือกใช้ข้อมูลที่มีความยาวอยู่ระหว่าง 80 – 510 ตัวอักษรเท่านั้น เพื่อที่จะได้ข้อความที่ไม่สั้นจนเกินไป หรือ ยาวเกินไปจนเกินขนาด Tokenizer หลังจากที่ผ่านมากระบวนการต่าง ๆ ที่กล่าวมาแล้ว จะได้จำนวนข้อมูลสุทธิอยู่ที่ 7,200 แถว ซึ่งได้มีการแบ่งไว้ฝึกโมเดลจำนวน 6,000 แถว และแบ่งไว้ทดสอบโมเดลอีกจำนวน 1,200 แถว ในจำนวนที่แต่ละคลาสมีจำนวนเท่ากัน เพื่อจะได้ไม่เกิดความเหลื่อมกันของข้อมูล

3.2.2 การปรับแต่งโมเดล (Fine-tuning)

หลังจากที่ได้จัดเตรียมชุดข้อมูลเป็นที่เรียบร้อยแล้ว ขั้นตอนถัดมาคือการนำข้อมูลเหล่านั้นมาใช้เพื่อ ฝึกและปรับแต่งโมเดล (Fine-tune) ซึ่งเป็นกระบวนการสำคัญที่ช่วยให้โมเดลสามารถเรียนรู้และเข้าใจบริบทของภาษาไทย รวมถึงความรู้เฉพาะทาง เช่น ลักษณะของภาษาที่ใช้ในรวิรร้านอาหารได้ดียิ่งขึ้น โดยโมเดลพื้นฐานที่เลือกใช้ในการฝึกครั้งนี้ คือ โมเดลภาษาขนาดใหญ่ (Large Language Model: LLM) ที่ได้รับการฝึกมาแล้วเบื้องต้น (Pre-trained Model) บนข้อมูลทั่วไปจำนวนมาก ซึ่งสามารถนำมาต่อยอดให้เหมาะกับงานเฉพาะทางผ่านการฝึกซ้ำ (retraining) บนข้อมูลใหม่ที่เกี่ยวข้องโดยตรงกับงาน

3.2.2.1 การเลือกโมเดลพื้นฐาน

โมเดลที่นำมาใช้ในการฝึกในโครงการนี้เป็นโมเดลในตระกูล Transformer ซึ่งเหมาะกับงานประมวลผลภาษาธรรมชาติ (NLP) โดยเฉพาะงานที่เกี่ยวข้องกับ ข้อความรวิรร ซึ่งมักมีรูปแบบภาษาที่หลากหลาย เช่น ภาษาพูด ภาษากึ่งทางการ คำซ้ำ และอีโมติคอน ฯลฯ โมเดลพื้นฐานที่เลือกใช้จะเป็นโมเดล WangchanBERTa ที่ถูกพัฒนาโดยทีมวิจัยของ AI Research Center, VISTEC ประเทศไทย โดยมีวัตถุประสงค์เพื่อพัฒนาโมเดลประมวลผลภาษาธรรมชาติที่สามารถเข้าใจ บริบทและความซับซ้อนของภาษาไทย ได้อย่างลึกซึ้ง โดยใช้เทคนิคการฝึกแบบเดียวกับ RoBERTa ที่ปรับปรุงจาก BERT และถูกฝึกเบื้องต้นมาจาก corpus ขนาดใหญ่ เช่น Wikipedia และ Wongnai โดย WangchanBERTa ถือเป็นโมเดล Pre-trained ภาษาไทยที่มีประสิทธิภาพสูง และมีให้เลือกใช้งานหลากหลายขนาด เช่น Base, Large และ Uncased โดยในโครงการนี้

ได้เลือกใช้ WangchanBERTa Base ซึ่งมีความสมดุลระหว่างความเร็วในการประมวลผลและความแม่นยำของโมเดล

เหตุผลที่ไม่เริ่มจากศูนย์ (Train from scratch) เนื่องจากโมเดลภาษาขนาดใหญ่ นั้นมีพารามิเตอร์จำนวนมาก การฝึกใหม่ตั้งแต่ต้นต้องใช้ทรัพยากรสูงและเวลาในการประมวลผลนานมาก การใช้โมเดลที่มีความรู้พื้นฐานอยู่แล้ว (Pre-trained) จึงเป็นแนวทางที่มีประสิทธิภาพและประหยัดทรัพยากร โดยสามารถใช้ข้อมูลจำนวนไม่มากเพื่อ fine-tune ให้เหมาะกับบริบทที่ต้องการ

3.2.2.2 กระบวนการ Fine-tuning

กระบวนการ Fine-tuning จะนำข้อมูลที่ได้จากขั้นตอนที่ 1 ซึ่งผ่านการกรองและจัดรูปแบบอย่างเหมาะสมแล้วมาใช้เป็น ตัวป้อน (Input) และ คำตอบที่ต้องการ (Target Output) ให้กับโมเดล โดยในโครงการนี้ จะโฟกัสไปที่การฝึกโมเดลให้สามารถทำการจัดระดับความพึงพอใจ จากข้อความรีวิว ซึ่งเป็นปัญหาประเภทการจัดประเภท (Text Classification)

กระบวนการ Fine-tuning ที่ใช้ในโครงการนี้ มีวัตถุประสงค์เพื่อให้โมเดล WangchanBERTa สามารถแยกแยะความรู้สึกของข้อความรีวิวได้แม่นยำขึ้น โดยเฉพาะในบริบทของรีวิวร้านอาหารในภาษาไทย ซึ่งมักมีการใช้ภาษาที่ไม่เป็นทางการ มีคำซ้ำ อีโมจิ หรือโครงสร้างประโยคที่ไม่ได้เป็นไปตามไวยากรณ์ทั่วไป

สเปคเครื่องคอมพิวเตอร์ที่ใช้ในการฝึกและทดสอบโมเดล

- CPU : AMD Ryzen 5 5600H with Radeon Graphics 3.30 GHz
- RAM : 16.0 GB
- GPU : NVIDIA GeForce RTX 3050 Ti Laptop GPU

การติดตั้งและเตรียมเครื่องมือ ก่อนเริ่มการฝึกโมเดลได้มีการติดตั้งไลบรารีเหล่านี้เพื่อรองรับการทำงาน

- transformers: ไลบรารีหลักจาก Hugging Face สำหรับโหลดและฝึกโมเดล
- thai2transformers: ไลบรารีเฉพาะสำหรับจัดการภาษาไทย เช่น Tokenizer และ Preprocessing
- datasets: สำหรับจัดการข้อมูลแบบ Dataset ซึ่งสามารถใช้ร่วมกับ Trainer ได้

- torch, pytorch_lightning: ใช้ในการฝึกโมเดลภายใต้สภาพแวดล้อมของ PyTorch
- ไลบรารีอื่น เช่น pythainlp, emoji, sentencepiece, tinydb, ฯลฯ ก็ถูกติดตั้งไว้เพื่อให้รองรับทุกการประมวลผลที่เกี่ยวข้องกับภาษาไทย

การโหลดข้อมูลเข้าสู่ระบบ ข้อมูลที่ใช้สำหรับฝึกโมเดลแบ่งเป็น 2 ชุด คือ ชุดข้อมูลที่ใช้สำหรับการฝึกโมเดล (training) จำนวน 6000 แถว และ ชุดข้อมูลที่ใช้สำหรับการประเมินผล จำนวน 1200 แถว ซึ่งแบ่งเป็นแต่ละคลาสอย่างเท่า ๆ กัน โดยในแต่ละชุดจะมีข้อมูลรีวิวที่แยกออกเป็น 2 คอลัมน์หลัก คือ text : ข้อความรีวิว (input) และ label : คะแนนระดับดาวตั้งแต่ 1 ถึง 5 (target output) ข้อมูลถูกอ่านเข้ามาผ่าน pandas.read_csv() แล้วแปลงเป็น datasets.Dataset เพื่อจะนำไปใช้งานกับ Trainer

การเลือกโมเดลและ Tokenizer ในขั้นตอนนี้ได้มีการเลือกโมเดลพื้นฐานเป็น 'wangchanberta-base-att-spm-uncased' โดยโมเดลนี้ใช้ Tokenizer แบบ SentencePiece ซึ่งสามารถจัดการคำในภาษาไทยได้อย่างมีประสิทธิภาพมากกว่า Tokenizer ทั่วไป เช่น WordPiece หรือ BPE ที่ใช้กับภาษาอังกฤษ จากนั้นนำข้อความทั้งหมดในชุดข้อมูลมาเข้ารหัสเป็น Token ผ่าน tokenizer(...) โดยตั้งค่า truncation=True และ padding='max_length' เพื่อให้ข้อความมีความยาวเท่ากันก่อนเข้าโมเดล ซึ่งเหมาะสำหรับการฝึกแบบ batch

ต่อมาการตั้งค่าพารามิเตอร์สำหรับการฝึก การฝึกโมเดลใช้คลาส TrainingArguments โดยมีการตั้งค่า

- num_train_epochs = 10 : ฝึกโมเดลจำนวน 10 รอบ
- per_device_train_batch_size = 16 : ขนาดชุดข้อมูลต่อหนึ่งรอบการฝึก
- evaluation_strategy = 'epoch' : วัดผลทุกครั้งที่จบ 1 epoch
- load_best_model_at_end = True : โหลดโมเดลที่ดีที่สุดหลังฝึกเสร็จ

การฝึกโมเดล (Fine-tuning) เมื่อทำการเตรียมข้อมูลเสร็จสิ้น ทั้งในรูปแบบของ datasets.Dataset สำหรับการฝึกและทดสอบ พร้อมกับการกำหนด Tokenizer ที่สอดคล้องกับโมเดล WangchanBERTa แล้ว ขั้นตอนถัดมาคือกระบวนการฝึกโมเดล ซึ่งถือเป็นขั้นตอนสำคัญของโครงการนี้ เนื่องจากเป็นขั้นตอนที่ทำให้โมเดลสามารถปรับตัวให้เข้าใจลักษณะเฉพาะของข้อมูลใหม่ที่เกี่ยวข้องกับบริบทของ “ข้อความรีวิวร้านอาหารภาษาไทย”

การฝึกโมเดล (Fine-tuning) คือกระบวนการนำโมเดลที่ถูก Pre-trained มาแล้วเบื้องต้น ให้เรียนรู้จากข้อมูลเฉพาะทางเพิ่มเติม โดยในที่นี้คือการเรียนรู้จากข้อความรีวิวที่มีการจัดระดับคะแนนดาวไว้ล่วงหน้า เพื่อให้โมเดลสามารถเรียนรู้ความสัมพันธ์ระหว่าง "ข้อความ" และ "ระดับความพึงพอใจ" ได้อย่างลึกซึ้งโมเดลที่โหลดจาก WangchanBERTa

การใช้ Trainer จาก Hugging Face เพื่อให้งานฝึกโมเดลมีประสิทธิภาพและจัดการได้ง่าย ได้เลือกใช้ Trainer ซึ่งเป็นคลาสสำเร็จรูปจากไลบรารี transformers ของ Hugging Face โดย Trainer ช่วยจัดการขั้นตอนที่ซับซ้อนของการฝึกโมเดลในระดับต่ำ เช่น การจัด Batch และ Padding, การจัดการ GPU/TPU, การคำนวณ Loss และการ Backpropagation, การวัดผลทุก Epoch และ การบันทึกโมเดลที่ดีที่สุดโดยอัตโนมัติ

Trainer จะรับค่าพารามิเตอร์สำคัญ 3 ส่วน ได้แก่

- **Model:** โมเดลหลักที่นำมา Fine-tune ซึ่งในกรณีนี้คือ wangchanberta-base-att-spm-uncased ที่โหลดมาผ่าน AutoModelForSequenceClassification
- **Tokenized Dataset:** ข้อมูลฝึกที่ผ่านการเข้ารหัส Token และจัดเป็นรูปแบบ Dataset ที่ประกอบด้วย input_ids, attention_mask, และ label
- **Compute Metrics:** ฟังก์ชันวัดผลการทำนายของโมเดล โดยกำหนดให้วัดค่าทั้ง Accuracy, Precision, Recall และ F1-score

การประเมินด้วย Cross-validation นอกเหนือจากการฝึกโมเดลแบบปกติแล้ว ในโครงงานนี้ยังได้มีใช้เทคนิค Cross-validation เพื่อประเมินประสิทธิภาพของโมเดลอย่างรอบด้านมากขึ้น โดยเฉพาะเพื่อหลีกเลี่ยงปัญหาการประเมินโมเดลจากชุดข้อมูลทดสอบเพียงชุดเดียว ซึ่งอาจไม่ครอบคลุมความหลากหลายของข้อความจริงในโลกความเป็นจริง

Cross-validation เป็นเทคนิคในการแบ่งข้อมูลฝึกออกเป็นหลายส่วน แล้วทำการฝึกและทดสอบโมเดลหลายรอบ โดยสลับชุดข้อมูลที่ใช้ฝึกและทดสอบไปเรื่อย ๆ เพื่อให้แน่ใจว่าโมเดลไม่ได้ “จดจำ” ข้อมูลเฉพาะกลุ่มใดกลุ่มหนึ่ง และสามารถวัดประสิทธิภาพได้อย่างเป็นธรรม

วิธีการที่ใช้ คือ Group K-Fold ในโค้ดมีการใช้ GroupKFold จาก sklearn.model_selection ซึ่งเป็นเทคนิคที่คล้ายกับ K-Fold ปกติ แต่จะ “ไม่แบ่งกลุ่มที่มีความเชื่อมโยงกันให้อยู่คนละ Fold” เช่น ถ้ามีรีวิวจากร้านอาหารเดียวกันหลายรายการ GroupKFold จะไม่แบ่งให้รีวิวของร้านนั้นกระจายอยู่ทั้งชุดฝึก

และชุดทดสอบพร้อมกัน เพราะอาจเกิดการรั่วไหลของข้อมูล (Data Leakage) โดยได้ตั้งค่า `GroupKFold(n_splits=5)` หมายความว่า จะทำการแบ่งข้อมูลออกเป็น 5 ส่วน (5-fold) แล้วทำการฝึกโมเดลทั้งหมด 5 รอบ โดยสลับกันใช้ข้อมูล 4 ส่วนสำหรับฝึก และอีก 1 ส่วนสำหรับทดสอบในแต่ละรอบ


ขั้นตอนของ Cross-validation ที่เกิดขึ้น

1. แบ่งข้อมูลเป็น 5 Fold ด้วย `GroupKFold`
2. ในแต่ละรอบของการฝึก (Fold 1 $\rightarrow$ Fold 5)
 - สร้าง Training Dataset และ Validation Dataset ใหม่
 - ทำ Tokenization กับทั้งสองชุด
 - ตั้งค่า Trainer ใหม่สำหรับ Fold นั้น ๆ
 - ฝึกโมเดลเฉพาะ Fold นั้น และเก็บผลลัพธ์ไว้
3. เก็บผลลัพธ์ทุก Fold เช่น Accuracy, F1-score
4. สรุปผลลัพธ์เฉลี่ย เพื่อให้เห็นภาพรวมประสิทธิภาพของโมเดล

ต่อมาหลังจากที่ได้ทำการฝึกโมเดลด้วย Cross-validation ได้ทำการเลือกโมเดลที่มีค่าความแม่นยำระหว่างการฝึกมากที่สุด นำมาทดสอบกับชุดข้อมูลทดสอบอีก 1200 แถว เพื่อให้ได้ค่าความแม่นยำของโมเดลที่จะนำไปใช้งานจริงต่อไป

3.2.3 การนำโมเดลมาใช้งานจริง

หลังจากที่ได้ทำการฝึกโมเดลด้วยชุดข้อมูลเฉพาะทาง และประเมินผลด้วยวิธีการ Cross-validation เพื่อให้มั่นใจในประสิทธิภาพของโมเดลแล้ว ขั้นตอนต่อมาคือการนำโมเดลที่ผ่านการฝึกมาใช้งานจริง (Inference) ผ่านระบบเว็บไซต์ที่พัฒนาไว้ ซึ่งเป็นหนึ่งในเป้าหมายหลักของโครงการนี้ การนำโมเดลมาใช้งานจริงเป็นการเปลี่ยนจากระบบการประมวลผลเชิงวิจัย ไปสู่ระบบที่สามารถรองรับการใช้งานของผู้ใช้ทั่วไป โดยให้ผู้ใช้สามารถพิมพ์ข้อความหรือลงในหน้าเว็บและได้รับผลลัพธ์เป็นระดับดาวที่ประเมินโดยโมเดลภาษาที่ถูกฝึกไว้ล่วงหน้า โดยภาพรวมของระบบจะเป็น ดังรูปภาพที่ 3.1



รูปภาพที่ 3.1 ภาพรวมของระบบ

ระบบเว็บไซต์ที่พัฒนาขึ้นนี้ถูกสร้างขึ้นโดยใช้เฟรมเวิร์ก Flask ซึ่งเป็นเครื่องมือพัฒนาเว็บแอปพลิเคชันด้วยภาษา Python ที่มีความเรียบง่าย ยืดหยุ่น และเหมาะกับงานที่ต้องการเชื่อมต่อโมเดลปัญญาประดิษฐ์กับระบบหลังบ้าน (Backend API) การพัฒนาเว็บไซต์นี้ครอบคลุมตั้งแต่การโหลดโมเดลและ Tokenizer ที่ผ่านการฝึกมาแล้ว การประมวลผลข้อความที่ผู้ใช้งานส่งเข้ามา การเรียกใช้งานโมเดล

เพื่อทำนายระดับความพึงพอใจ ไปจนถึงการจัดการผลลัพธ์ให้อยู่ในรูปแบบที่สามารถแสดงผลบนหน้าเว็บได้อย่างเหมาะสม

เมื่อระบบเริ่มทำงาน Flask จะทำหน้าที่เป็น Web Server โดยโหลดโมเดล WangchanBERTa ที่ผ่านการ Fine-tune มาแล้วจากโพลเดอร์ที่จัดเก็บไฟล์โมเดลไว้ ไม่ว่าจะเป็นโครงสร้างโมเดล ไฟล์น้ำหนัก (weights) หรือไฟล์ที่เกี่ยวข้องกับ Tokenizer ข้อมูลเหล่านี้จะถูกโหลดเข้าสู่หน่วยความจำเพื่อเตรียมพร้อมใช้งานทันที ผู้ใช้งานที่เข้ามาที่หน้าเว็บไซต์จะพบกับอินเทอร์เฟซที่มีลักษณะคล้ายกล่องแชท ซึ่งออกแบบมาให้เป็นมิตรกับผู้ใช้งาน โดยมีช่องสำหรับกรอกข้อความรีวิว และปุ่มสำหรับส่งข้อความไปยังระบบเบื้องหลัง

เมื่อผู้ใช้งานพิมพ์ข้อความรีวิวลงไป ช่องกรอกข้อความ และกดปุ่มส่ง ระบบจะทำการส่งข้อความไปยังเซิร์ฟเวอร์ผ่านคำขอแบบ HTTP POST ซึ่ง Flask จะทำหน้าที่รับข้อความนั้น และแปลงข้อความเป็น Token โดยใช้ Tokenizer ที่ตรงกับโมเดล หลังจากนั้นจะป้อน Token เหล่านี้เข้าไปยังโมเดล WangchanBERTa เพื่อทำการประมวลผล โมเดลจะวิเคราะห์ความรู้สึกที่แฝงอยู่ในข้อความรีวิว และประเมินว่ารีวิวนั้นควรได้รับระดับความพึงพอใจที่เท่าใด ตั้งแต่ 1 ถึง 5 ดาว โดยอาศัยความสัมพันธ์ของ คำ วลี และโครงสร้างภาษาที่ปรากฏอยู่ในข้อความ จากนั้นระบบจะส่งผลลัพธ์กลับไปยังส่วนแสดงผลของเว็บไซต์ในรูปแบบ JSON ซึ่งจะถูกนำไปแสดงบนหน้าจอของผู้ใช้งานในรูปแบบของไอคอนดาวที่แสดงจำนวนดาวที่โมเดลประเมิน

นอกจากนี้ยังมีฟังก์ชันเพิ่มเติมสำหรับผู้ใช้งานที่ต้องการดูรายละเอียดเชิงลึกของผลการประเมิน เช่น ค่า logit หรือความมั่นใจของแต่ละคลาสที่โมเดลคำนวณได้ ซึ่งสามารถดูเพิ่มเติมได้ผ่านปุ่มที่แสดงอยู่ข้างระดับดาว ผลลัพธ์เหล่านี้ไม่เพียงแต่ช่วยให้ผู้ใช้งานเข้าใจระบบมากขึ้น แต่ยังเป็นประโยชน์ต่อผู้พัฒนาในการวิเคราะห์และปรับปรุงระบบในอนาคต

ระบบทั้งหมดได้ถูกเผยแพร่บนแพลตฟอร์ม Render ซึ่งเป็นผู้ให้บริการเว็บโฮสติ้งที่รองรับแอปพลิเคชัน Python และมีความสามารถในการประมวลผลโมเดลที่ใช้ทรัพยากรในระดับปานกลาง การใช้งานผ่าน Render ช่วยให้ผู้ใช้งานสามารถเข้าถึงเว็บไซต์ได้จากทุกที่โดยไม่ต้องติดตั้งซอฟต์แวร์ใด ๆ เพิ่มเติม อย่างไรก็ตาม เนื่องจาก Render เป็นบริการฟรี (ในแผนใช้งานปัจจุบัน) ระบบอาจเข้าสู่โหมดพัก (sleep mode) หากไม่มีการเรียกใช้งานในช่วงเวลาหนึ่ง ซึ่งจะทำให้ต้องรอประมาณ 2-3 นาทีในการเปิดใช้งานครั้งแรกของวัน

บทที่ 4

ผลการทดสอบ

4.1 ผลการสอบระบบโดยรวม

ระบบที่พัฒนาขึ้นในโครงการนี้เป็นระบบวิเคราะห์ความรู้สึกจากข้อความรีวิวร้านอาหารภาษาไทย โดยใช้โมเดล WangchanBERTa ที่ผ่านการปรับแต่ง (Fine-tune) ด้วยชุดข้อมูลความคิดเห็นที่มีการจำแนกระดับคะแนน (1–5 ดาว) อย่างสมดุล เป้าหมาย คือ การทำนายระดับคะแนนจากข้อความอย่างแม่นยำที่สุด

เพื่อวัดผลประสิทธิภาพของระบบ ได้มีการทดลองปรับค่าพารามิเตอร์หลักที่ละตัว ได้แก่ Dropout, Batch Size, Epoch และ Data Size โดยใช้เงื่อนไขการทดลองเดียวกัน ได้แก่ Fold = 5, Epoch = 10, Train Batch Size = 16, Eval Batch Size = 32, Dropout = 0.2, Data Size = 5000 (ยกเว้นตัวแปรที่อยู่ระหว่างการทดสอบ)

4.1.1 การทดสอบ Dropout

ตารางที่ 2.1 การทดสอบ Dropout

DropOut	Mean Validation
0.1	0.6124
0.2	0.7720
0.3	0.4677
0.4	0.3668

ผลการทดลองพบว่า Dropout ที่ 0.2 ให้ผลลัพธ์ที่ดีที่สุด โดยได้ค่า Mean Validation = 0.7720 ขณะที่ค่า Dropout ที่มากเกินไป (0.3 และ 0.4) ดังตารางที่ 4.1 ทำให้โมเดลมีประสิทธิภาพลดลง แสดงให้เห็นว่าค่า Dropout ที่มากเกินไปอาจลดความสามารถในการเรียนรู้ของโมเดล

4.1.2 การทดสอบ Batch Size

ตารางที่ 4.2 การทดสอบ Batch Size

Train Batch Size	Eval Batch Size	Mean Validation
4	8	0.5370
8	16	0.7720
16	32	0.7966
32	64	0.6720

การเปลี่ยนแปลงขนาด Batch แสดงให้เห็นว่า ขนาด Train = 16 / Eval = 32 ให้ผลลัพธ์ที่ดีที่สุด โดยได้ค่า Mean Validation = 0.7966 ดังตารางที่ 4.2 ขนาดที่เล็ก หรือ ใหญ่เกินไปมีผลต่อประสิทธิภาพของโมเดล

4.1.3 การทดสอบ Epoch

ตารางที่ 4.3 การทดสอบ Epoch

Epoch	Mean Validation
5	0.5784
10	0.7374
15	0.6356
20	0.7033

จำนวน Epoch ที่เหมาะสมที่สุดคือ 10 รอบ โดยให้ Mean Validation สูงที่สุดที่ 0.7374 ดังตารางที่ 4.3 หาก Epoch ต่ำกว่านี้อาจเกิด Underfitting และหากสูงเกินไปอาจเกิด Overfitting

4.1.4 การทดสอบ Data Size

ตารางที่ 4.4 การทดสอบ Data Size

Data Size	Mean Validation
4000	0.6779
5000	0.7374
6000	0.8262
7000	0.7420

การเพิ่มขนาดข้อมูลจาก 4000 → 6000 ตัวอย่างทำให้ประสิทธิภาพของโมเดลเพิ่มขึ้นอย่างชัดเจน โดย Data Size = 6000 ให้ Mean Validation สูงที่สุด (0.8262) ขนาด 7000 กลับลดลงเล็กน้อย ดังตารางที่ 4.4 แม้ข้อมูลจะสมดุล แต่ข้อความใหม่ที่กำกวมหรือซับซ้อน อาจทำให้โมเดลวิเคราะห์ยากขึ้น


สรุปภาพรวม

จากการทดสอบพบว่าโมเดลมีประสิทธิภาพที่ดีขึ้นเมื่อมีการปรับพารามิเตอร์อย่างเหมาะสม โดยค่าที่ให้ผลดีที่สุดคือ Dropout = 0.2, Train Batch Size = 16, Eval Batch Size = 32, Epoch = 10 และ Data Size = 6000 โดยโมเดลที่ได้ภายใต้เงื่อนไขนี้มี Mean Validation สูงสุดที่ 0.8262 ซึ่งสะท้อนถึงความสามารถในการนำระบบไปใช้งานจริงอย่างมีประสิทธิภาพ


หลังจากนั้นได้มีการนำค่าพารามิเตอร์ ที่ได้จากการทดลองแล้วว่ามีประสิทธิภาพสูงที่สุดในการใช้ฝึก มาทำการฝึกโมเดล จึงได้ผลระหว่างการฝึกที่ดีที่สุดคือ Fold ที่ 5 จะเห็นได้ว่าใน epoch ที่ 1 ค่าความแม่นยำพุ่งขึ้นไปสูงถึง 0.97 แล้วลดลงมา และเมื่อดูค่าของ Training Loss และ Validation Loss ควบคู่ไปด้วยจะเห็นได้ว่าเพิ่มสูงขึ้น นั่นแปลว่าโมเดลเริ่มหยุดการฝึกต่อหลังจากจุดนี้แล้ว ดังรูปภาพที่ 4.1 และ 4.2 คงจะเป็นเพราะโมเดลได้ทำการฝึกมาจนถึงจุดที่รับข้อมูลมากพอแล้วจาก 4 Fold ที่ผ่านมา เราได้โมเดลสุดท้ายออกมาที่จุด checkPoint นี้ โดยแสดงผลการฝึกได้ ดังตารางที่ 4.5

ตารางที่ 4.5 ผลระหว่างการฝึกที่ดีที่สุด

Epoch	Training Loss	Validation Loss	Accuracy
1	0.380200	0.121213	0.969167
2	0.473100	0.255754	0.895000
3	0.304800	0.221135	0.916667
4	0.274100	0.216003	0.920000
5	0.210000	0.254214	0.900000
6	0.096600	0.277149	0.902500
7	0.190300	0.248328	0.915000
8	0.087100	0.271710	0.916667
9	0.075500	0.261643	0.921667
10	0.032800	0.280606	0.921667



รูปภาพที่ 4.1 กราฟระหว่าง Training , Validation Loss เทียบ Epoch



รูปภาพที่ 4.2 กราฟระหว่าง Accuracy เทียบ Epoch

4.2 ผลการทดสอบโมเดลที่มีประสิทธิภาพดีที่สุด

หลังจากดำเนินการทดลองปรับค่าพารามิเตอร์หลักในระบบแล้ว ได้เลือกค่าที่ให้ประสิทธิภาพดีที่สุด ได้แก่

DropOut = 0.2, Train Batch Size / Eval Batch Size = 16 / 32, Epoch = 10, และ Data Size = 6000

ตัวอย่าง เมื่อทำการประเมินโมเดลด้วยชุดทดสอบขนาด 1,200 ตัวอย่าง ได้ผลลัพธ์ดังนี้:

4.2.1 สรุปผลการประเมินประสิทธิภาพของโมเดล


ตารางที่ 4.6 ผลการทดสอบโมเดลพื้นฐาน (Base Model) เทียบกับ โมเดลที่ดีที่สุด (Final Model)

	Base Model	Final Model
Accuracy	65.75%	80.42%
Precision	66.54%	81.45%
Recall	65.75%	80.42%
F1-score	65.28%	80.45%
Samples	1200	1200


ตารางที่ 4.7 Classification Report ของโมเดลพื้นฐาน (Base Model) เทียบกับโมเดลที่ดีที่สุด (Final Model)

Class (ดาว)	Precision		Recall		F1-score		Support
	Base	Final	Base	Final	Base	final	
1	0.7619	0.8404	0.5333	0.7458	0.6275	0.7903	240
2	0.5657	0.7098	0.4667	0.7542	0.5114	0.7313	240
3	0.6617	0.7801	0.7417	0.9458	0.6994	0.8550	240
4	0.5890	0.7738	0.8000	0.8125	0.6784	0.7927	240
5	0.7490	0.9683	0.7458	0.7625	0.7474	0.8531	240

4.2.2 การทำนายผลด้วย Confusion Matrix



รูปภาพที่ 4.3 Confusion Matrix Base Model



รูปภาพที่ 4.4 Confusion Matrix Fine-Tune Model

4.2.3 บทวิเคราะห์ผลการเปรียบเทียบ

จากการทดลองประเมินผลด้วยโมเดลพื้นฐาน (Base Model) พบว่าโมเดลดังกล่าวสามารถทำค่าความแม่นยำ (Accuracy) ได้เพียง 65.75% ดังตารางที่ 4.6 โดยมีค่า F1-score เฉลี่ยอยู่ที่ 65.28% ดังตารางที่ 4.7 ซึ่งเมื่อพิจารณาร่วมกับกราฟ Confusion Matrix ดังรูปภาพที่ 4.3 จะเห็นว่าโมเดลยังมีข้อจำกัดในการจำแนกความแตกต่างของระดับคะแนนความคิดเห็น โดยเฉพาะในคลาสที่ 1 และ 2 ซึ่งมีการทำนายผิดไปยังคลาสอื่นจำนวนมาก เช่น คลาส 1 ที่มีการทำนายผิดไปเป็นคลาส 5 ถึง 11 ตัวอย่าง จากทั้งหมด 240 ตัวอย่างในคลาสนั้น ซึ่งเป็นการทำนายที่มีความคลาดเคลื่อนสูง

ข้อผิดพลาดลักษณะนี้สะท้อนให้เห็นว่าโมเดลยังไม่สามารถเข้าใจความแตกต่างของน้ำเสียงหรือบริบทในข้อความได้ดีพอ โดยเฉพาะในกรณีที่ข้อความมีทั้งแง่บวกและแง่ลบในประโยคเดียวกัน หรือในข้อความที่ใช้ถ้อยคำกลาง ๆ ที่ตีความได้หลากหลาย ความกำกวมเช่นนี้ทำให้โมเดลเกิดความสับสนในการตัดสินระดับคะแนน ส่งผลให้เกิดการทำนายผิดที่มีระยะห่างมากกว่า 1 ระดับดาว

อย่างไรก็ตาม เมื่อมีการนำโมเดลเดิมมาทำการ ปรับแต่งเพิ่มเติม (Fine-tune) ด้วยข้อมูลที่สะอาดขึ้นและมีจำนวนตัวอย่างเท่า ๆ กันในแต่ละคลาส ส่งผลให้ประสิทธิภาพของโมเดลดีขึ้นอย่างชัดเจน โดยค่าความแม่นยำเพิ่มขึ้นเป็น 80.42% และค่า F1-score เฉลี่ยอยู่ที่ 80.45% จากกราฟ Confusion Matrix ดังรูปภาพที่ 4.4 จะเห็นว่าโมเดลสามารถจำแนกข้อมูลได้ดีขึ้นมาก โดยเฉพาะในคลาสที่ 3 และ 5 ที่มีค่า Recall อยู่ที่ 0.9458 และ

0.7625 ตามลำดับ ดังตารางที่ 4.7 ซึ่งแสดงให้เห็นถึงความสามารถของโมเดลในการแยกแยะคลาสที่มีลักษณะเฉพาะเจาะจงได้ดีขึ้น แม้ว่าจะยังคงมีข้อผิดพลาดอยู่บ้าง แต่ส่วนใหญ่เป็นการคลาดเคลื่อนเพียง 1 ระดับดาว ซึ่งถือว่าอยู่ในเกณฑ์ที่ยอมรับได้ และไม่รุนแรงเท่ากับโมเดลพื้นฐานที่มีการทำนายผิดถึง 3–4 ระดับ ความเปลี่ยนแปลงนี้แสดงให้เห็นว่า การปรับ Fine-tune ด้วยข้อมูลที่เหมาะสมและการตั้งค่าพารามิเตอร์อย่างเหมาะสม เช่น การตั้งค่า DropOut, Batch Size และจำนวน Epoch ที่เหมาะกับขนาดข้อมูล ช่วยยกระดับความสามารถของโมเดลได้อย่างมีนัยสำคัญ


โดยสรุป การเปรียบเทียบระหว่างโมเดลพื้นฐานและโมเดลที่ผ่านการปรับแต่ง แสดงให้เห็นถึงความสำคัญของคุณภาพข้อมูลและการตั้งค่าการฝึกโมเดลที่เหมาะสม ซึ่งมีผลต่อความแม่นยำและความสามารถในการจำแนกข้อความของโมเดลอย่างชัดเจน

4.3 ผลการทดสอบจากผู้ใช้งานจริง

4.3.1 แบบสอบถามของเว็บแอปพลิเคชันด้านการทำนายผลของโมเดล

ผลการทดสอบจากผู้ใช้งานจริงของเว็บแอปพลิเคชันด้านการทำนายผลของโมเดล จากผู้ทดลองจำนวน 13 คน ผู้ใช้พึงพอใจ เนื่องจากสามารถวิเคราะห์ผลระดับดาวของข้อความรีวิวได้อย่างแม่นยำถูกต้อง และน่าเชื่อถือ ดังรูปภาพที่ 4.5

ด้านการทำนายผลของโมเดล




รูปภาพที่ 4.5 ผลการตอบแบบสอบถามด้านการทำนายผลของโมเดล

4.3.2 แบบสอบถามของเว็บแอปพลิเคชันด้านการออกแบบเว็บไซต์

ผลการทดสอบจากผู้ใช้งานของเว็บแอปพลิเคชันด้านการออกแบบเว็บไซต์ จากผู้ทดลองจำนวน 13 คน โดยมีผลการทดสอบ ดังรูปภาพที่ 4.6

ด้านของการออกแบบเว็บไซต์




รูปภาพที่ 4.6 ผลการตอบแบบสอบถามด้านการออกแบบเว็บไซต์

4.3.3 แบบสอบถามของเว็บแอปพลิเคชันด้านการนำไปใช้งานจริง

ผลการทดสอบจากผู้ใช้งานของเว็บแอปพลิเคชันด้านการนำไปใช้งานจริง จากผู้ทดลองจำนวน 13 คน โดยมีผลการทดสอบ ดังรูปภาพที่ 4.7

ด้านการนำไปใช้งานจริง



รูปภาพที่ 4.7 ผลการตอบแบบสอบถามด้านการนำไปใช้งานจริง

บทที่ 5

สรุปและข้อเสนอแนะ

5.1 สรุปและข้อเสนอแนะ

การพัฒนาโครงงาน การวิเคราะห์เชิงความรู้สึกจากรีวิวร้านอาหารภาษาไทย มีวัตถุประสงค์คือ เพื่อพัฒนาระบบการวิเคราะห์ความรู้สึก (Sentiment Analysis) จากข้อความภาษาไทย ให้สามารถวิเคราะห์ผลออกมาได้แม่นยำ และเพื่ออำนวยความสะดวกแก่ผู้ใช้ ทั้งผู้ใช้บริการ หรือ เจ้าของกิจการ โดยที่ผู้ใช้ไม่จำเป็นต้องอ่านรีวิวเอง ก็สามารถทราบระดับความพึงพอใจของข้อความรีวิวนั้นได้อย่างง่ายดาย

โดยในโครงงานนี้จะประกอบไปด้วย 2 ส่วนหลัก ๆ คือ ส่วนของตัวโมเดล และ หน้าเว็บไซต์ สำหรับเข้าใช้งาน ซึ่งมีรายละเอียดดังนี้

โมเดลที่ได้มาจากการฝึกฝนโมเดล WangchanBERTa เพิ่มเติม ด้วยข้อมูลชุดที่ใหม่กว่าและสะอาดขึ้น รวมไปถึงมีการกระจายตัวอย่างเท่ากันในทุก ๆ คลาส เพื่อให้สามารถทำนายได้อย่างแม่นยำมากยิ่งขึ้น

หน้าเว็บไซต์สำหรับเข้าใช้งาน มีหน้าที่ในการติดต่อสื่อสารระหว่างตัวโมเดล และ ผู้ใช้งาน รวมไปถึงเพิ่มความง่ายและสะดวกสบายในการเข้าถึงโมเดล

เมื่อทำการทดสอบการใช้งานของระบบ สรุปได้ว่า ทั้งสองส่วนสามารถทำงานร่วมกันได้ดี และมีประสิทธิภาพมากพอที่จะนำไปใช้งานจริงได้

5.2 แนวทางการพัฒนา

- 5.2.1 พัฒนาโมเดลให้มีค่าความแม่นยำที่สูงขึ้นกว่านี้
- 5.2.2 เพิ่มข้อมูลจากแหล่งต่าง ๆ เพื่อขยายขอบเขตการเรียนรู้
- 5.2.3 ปรับแต่งโมเดลให้สามารถทำงานกับหลายภาษา (Multilingual)

ภาคผนวก

ก1

คู่มือการติดตั้งระบบ

เว็บไซต์สำหรับเข้าใช้งานระบบวิเคราะห์ความคิดเห็นจากรีวิวร้านอาหาร สามารถเข้าถึงได้ผ่านลิงก์ต่อไปนี้ <https://sentiment-analysis-gjbh.onrender.com/> หรือสามารถสแกนคิวอาร์โค้ดด้านล่างเพื่อเข้าสู่หน้าเว็บไซต์โดยตรง



รูปภาพที่ ก.1.1 คิวอาร์โค้ดเข้าใช้งานเว็บไซต์

หากเว็บไซต์ไม่มีการเปิดใช้งานเป็นระยะเวลานาน (idle) ระบบอาจใช้เวลาในการเริ่มต้นเซิร์ฟเวอร์ประมาณ 2-3 นาที หลังจากคลิกลิงก์หรือสแกนคิวอาร์โค้ด เพื่อเตรียมความพร้อมของเซิร์ฟเวอร์ก่อนเข้าสู่หน้าเว็บไซต์ เมื่อโหลดเสร็จสมบูรณ์แล้ว ผู้ใช้งานสามารถใช้งานระบบได้ตามปกติ โดยไม่ต้องติดตั้งซอฟต์แวร์เพิ่มเติมใด ๆ

ก2

คู่มือการใช้งาน

การใช้งานของเว็บไซต์ที่พัฒนาเพื่อให้ผู้ใช้งานสามารถทดลองระบบวิเคราะห์ความพึงพอใจของข้อความรีวิวร้านอาหารผ่านโมเดลที่ได้รับการฝึกแบบเฉพาะทาง (Fine-tuned) บนโมเดลภาษาไทย WangchanBERTa

โครงสร้างของหน้าเว็บไซต์ เว็บไซต์แบ่งการแสดงผลออกเป็น 3 ส่วนหลัก ได้แก่


1. พื้นที่แสดงข้อความสนทนา (Chat Area) อยู่ทางฝั่งซ้ายของหน้าจอ ประกอบด้วย:

- ข้อความที่ผู้ใช้พิมพ์เข้ามา (แสดงในช่องสีเทา)
- ผลลัพธ์ที่โมเดลตอบกลับมาในรูปของระดับดาว (1–5 ดาว) ซึ่งเป็นผลจากการประมวลผลความรู้สึก (Sentiment) ของข้อความรวิวนั้น ๆ

2. แถบข้อมูลด้านขวา (Information Panel) จัดแสดงข้อมูลเบื้องต้นของระบบ

3. ช่องพิมพ์ข้อความและส่งรีวิว (Input Area) อยู่ด้านล่างสุดของหน้าจอ มีลักษณะเหมือนกล่องแชททั่วไป โดยผู้ใช้งานสามารถ

- พิมพ์ข้อความรวิวลงไป โดยระบบจะสามารถทำงานได้ดีที่สุดกับข้อความที่เกี่ยวข้องกับ ประสบการณ์การรับประทานอาหารหรือการใช้บริการร้านอาหาร
- กดปุ่ม ส่ง (Send) เพื่อให้ระบบประมวลผลข้อความ
- รอผลลัพธ์แสดงกลับมาเป็นระดับดาว
- หากต้องการดูข้อมูลดิบ (Raw Output) หรือคะแนนความมั่นใจของโมเดล จะมีปุ่ม "INFO" ให้กดดูรายละเอียดเพิ่มเติม ข้าง ๆ ระดับดาวที่แสดง



รูปภาพที่ ก.2.1 หน้าเว็บไซต์

ก3

ผลการทดสอบแต่ละตัวอย่าง

ร้านนี้การบริการไม่ได้เรื่องไม่สนใจลูกค้าแย่มาก ร้านสกปรกมาก อาหารรสห่วยแตก จะไม่มาเหยียบที่นี่อีก

★

อาหารร้านนี้ออกได้โดยว่าไม่ถูกปากค่ะรสชาติเค็มเกินไปทานไม่ได้แน่ค่ะ

★ ★

ไก่ทอดร้านนี้รสชาติธรรมดาไม่น่ามีอะไรพิเศษตามที่เขามอบ ร้านบริการอยู่ในระดับโอเค ร้านมีที่จอดรถ ธรรมดาแล้วเฉยๆ

★ ★ ★

คัมปาลีที่รสชาติดีค่ะ ที่ร้านมีสนามเด็กเล่น เด็กๆชอบ แอมนี่ที่จอดรถกว้างด้วย ธรรมดาแล้วดีค่ะ

★ ★ ★ ★

ทีมร้านนี้อร่อยมากทุกอย่างเลย หอยลายผัดแซ่บอร่อยเหาะ กินแล้วแสงออกปาก พนักงานบริการดีเลิศ ที่จอดรถกว้างขวาง ธรรมดาแล้วประทับใจมาก แนะนำค่ะ

★ ★ ★ ★ ★


รูปภาพที่ ก.3.1 ผลการทดสอบแต่ละตัวอย่าง

ก4

ผลลัพธ์การตอบแบบสอบถามแต่ละบุคคล


ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป จากผู้ทดลองใช้จำนวน 13 คน

เพศ
ค่าตอบ 13 ข้อ




รูปภาพที่ ก.4.1 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – เพศ

อายุ
ค่าตอบ 13 ข้อ



รูปภาพที่ ก.4.2 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – อายุ


สถานภาพ
คำตอบ 13 ข้อ



รูปภาพที่ ก.4.3 ผลลัพธ์การตอบแบบสอบถามด้านข้อมูลทั่วไป – สถานภาพ

ผลลัพธ์การตอบแบบสอบถามด้านการทำนายผลของโมเดล จากผู้ทดลองใช้จำนวน 13 คน


ด้านการทำนายผลของโมเดล



รูปภาพที่ ก.4.4 ผลลัพธ์การตอบแบบสอบถามด้านการทำนายผลของโมเดล

ผลลัพธ์การตอบแบบสอบถามด้านของการออกแบบเว็บไซต์ จากผู้ทดลองใช้จำนวน 13 คน


ด้านของการออกแบบเว็บไซต์



รูปภาพที่ ก.4.5 ผลลัพธ์การตอบแบบสอบถามด้านของการออกแบบเว็บไซต์

ผลลัพธ์การตอบแบบสอบถามด้านของการนำไปใช้งานจริง จากผู้ทดลองใช้จำนวน 13 คน

ด้านของการนำไปใช้งานจริง



รูปภาพที่ ก.4.6 ผลลัพธ์การตอบแบบสอบถามด้านของการนำไปใช้งานจริง

ก5

แหล่งเก็บชุดข้อมูล โปรแกรม และโมเดลของโครงการ

โค้ดต้นฉบับ โมเดลที่ผ่านการฝึก และไฟล์ประกอบการทดลองทั้งหมดที่เกี่ยวข้องกับโครงการฉบับนี้

ได้รับการจัดเก็บไว้บน GitHub และสามารถเข้าถึงได้ผ่านลิงก์ต่อไปนี้:

<https://github.com/Aissariya/Sentiment-Analysis-on-Thai-Language-Restaurant-Reviews>

เอกสารอ้างอิง

- [1] J. K. Ayeh, N. Au, and R. Law, “‘Do We Believe in TripAdvisor?’ Examining Credibility Perceptions and Online Travelers’ Attitude toward Using User-Generated Content,” *J. Travel Res.*, vol. 52, no. 4, pp. 437–452, Jul. 2013, doi: 10.1177/0047287512475217.
- [2] N. Jindal and B. Liu, “Opinion spam and analysis,” in *Proceedings of the international conference on Web search and web data mining - WSDM '08*, Palo Alto, California, USA: ACM Press, 2008, p. 219. doi: 10.1145/1341531.1341560.
- [3] L. Lowphansirikul, C. Polpanumas, N. Jantrakulchai, and S. Nutanong, “WangchanBERTa: Pretraining transformer-based Thai Language Models,” Mar. 20, 2021, *arXiv*: arXiv:2101.09635. doi: 10.48550/arXiv.2101.09635.
- [4] S. Singkul, B. Khampinyot, N. Maharattamalai, S. Taerungruang, and T. Chalothorn, “Parsing Thai Social Data: A New Challenge for Thai NLP,” Mar. 06, 2020, *arXiv*: arXiv:2003.03069. doi: 10.48550/arXiv.2003.03069.
- [5] B. Liu, *Sentiment Analysis: Mining Opinions, Sentiments, and Emotions*. Cambridge University Press, 2020.
- [6] A. Agarwal, “Sentiment Analysis of Financial News,” in *2020 12th International Conference on Computational Intelligence and Communication Networks (CICN)*, Sep. 2020, pp. 312–315. doi: 10.1109/CICN49253.2020.9242579.
- [7] J. C. Gope, T. Tabassum, M. Md. Mabur, K. Yu, and M. Arifuzzaman, “Sentiment Analysis of Amazon Product Reviews Using Machine Learning and Deep Learning Models,” in *2022 International Conference on Advancement in Electrical and Electronic Engineering (ICAEEE)*, Feb. 2022, pp. 1–6. doi: 10.1109/ICAEEE54957.2022.9836420.
- [8] H. Kumar, A. Kumar, A. Anand, A. Sabu, and T. Jain, “Sentiment Analysis on Amazon Electronics Product Reviews using Machine Learning Techniques,” in *2023 4th IEEE Global Conference for Advancement in Technology (GCAT)*, Oct. 2023, pp. 1–6. doi: 10.1109/GCAT59970.2023.10353467.

- [9] N. Khamphakdee and P. Seresangtakul, "An Efficient Deep Learning for Thai Sentiment Analysis," *Data*, vol. 8, no. 5, Art. no. 5, May 2023, doi: 10.3390/data8050090.
- [10] Q. T. Nguyen, T. L. Nguyen, N. H. Luong, and Q. H. Ngo, "Fine-Tuning BERT for Sentiment Analysis of Vietnamese Reviews," in *2020 7th NAFOSTED Conference on Information and Computer Science (NICS)*, 2020, pp. 302–307. doi: 10.1109/NICS51282.2020.9335899.
- [11] T. Kuhamanee, N. Talmongkol, K. Chaisuriyakul, W. San-Um, N. Pongpisuttinun, and S. Pongyupinpanich, "Sentiment analysis of foreign tourists to Bangkok using data mining through online social network," in *2017 IEEE 15th International Conference on Industrial Informatics (INDIN)*, Jul. 2017, pp. 1068–1073. doi: 10.1109/INDIN.2017.8104921.
- [12] P. Jiranantanagorn and T. Puangsuwan, "Thai Sentiment Analysis and Visualization of Movie Reviews From Social Media," in *2022 6th International Conference on Information Technology (InCIT)*, Nov. 2022, pp. 100–104. doi: 10.1109/InCIT56086.2022.10067441.
- [13] C. Piyaphakdeesakun, N. Facundes, and J. Polvichai, "Thai Comments Sentiment Analysis on Social Networks with Deep Learning Approach," in *2019 34th International Technical Conference on Circuits/Systems, Computers and Communications (ITC-CSCC)*, Jun. 2019, pp. 1–4. doi: 10.1109/ITC-CSCC.2019.8793324.
- [14] P. Harnmetta and T. Samanchuen, "Sentiment Analysis of Thai Stock Reviews Using Transformer Models," in *2022 19th International Joint Conference on Computer Science and Software Engineering (JCSSE)*, Jun. 2022, pp. 1–6. doi: 10.1109/JCSSE54890.2022.9836278.
- [15] A. Vaswani *et al.*, "Attention is All you Need," in *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2017. Accessed: Nov. 01, 2024. [Online]. Available: https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html
- [16] P. Nakwijit, "ทำความเข้าใจ Transformer [Part I]," Medium. Accessed: Apr. 06, 2025. [Online]. Available: <https://medium.com/@chameleontk/%E0%B8%97%E0%B8%B3%E0%B8%84%E0%B8%A7%E0%>

B8%B2%E0%B8%A1%E0%B9%80%E0%B8%82%E0%B9%89%E0%B8%B2%E0%B9%83%E0%B8%88-transformer-part-i-a50dcf06579b

[17] K. Xu *et al.*, “Show, Attend and Tell: Neural Image Caption Generation with Visual Attention,” Apr. 19, 2016, *arXiv*: arXiv:1502.03044. doi: 10.48550/arXiv.1502.03044.

[18] “The Attention Mechanism and the Transformer Model.” Accessed: Apr. 06, 2025. [Online]. Available: <https://deepfrench.gitlab.io/deep-learning-project/>

[19] P. Nakwijit, “ทำความเข้าใจ Transformer [Part II],” Medium. Accessed: Apr. 06, 2025. [Online]. Available: <https://medium.com/@chameleontk/%E0%B8%97%E0%B8%B3%E0%B8%84%E0%B8%A7%E0%B8%B2%E0%B8%A1%E0%B9%80%E0%B8%82%E0%B9%89%E0%B8%B2%E0%B9%83%E0%B8%88-transformer-part-ii-e2b467a70a45>

[20] A. Vaswani *et al.*, “Attention Is All You Need,” Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.

[21] “Deep Neural Networks Bring Patterns into Focus | Science & Technology Review.” Accessed: Apr. 06, 2025. [Online]. Available: <https://str.llnl.gov/past-issues/june-2016/deep-neural-networks-bring-patterns-focus>

[22] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” Dec. 10, 2015, *arXiv*: arXiv:1512.03385. doi: 10.48550/arXiv.1512.03385.

[23] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” May 24, 2019, *arXiv*: arXiv:1810.04805. doi: 10.48550/arXiv.1810.04805.

[24] P. Nakwijit, “ทำความเข้าใจ BERT,” Medium. Accessed: Apr. 06, 2025. [Online]. Available: <https://medium.com/@chameleontk/%E0%B8%97%E0%B8%B3%E0%B8%84%E0%B8%A7%E0%B8%B2%E0%B8%A1%E0%B9%80%E0%B8%82%E0%B9%89%E0%B8%B2%E0%B9%83%E0%B8%88-bert-98589715545>

[25] “WangchanBERTa: Pre-trained Thai Language Model,” airesearch.in.th. Accessed: Apr. 01, 2025. [Online]. Available: <https://airesearch.in.th/releases/wangchanberta-pre-trained-thai-language-model/>

Plagiarism Checking Report

Created on 2025-04-01 19:45:05 at 19:45 PM

Submission Information

ID	SUBMISSION DATE	SUBMITTED BY	ORGANIZATION	FILENAME	STATUS	SIMILARITY INDEX
4217885	Apr 1, 2025 at 19:40 PM	aissariya.t@ku.th	มหาวิทยาลัยเกษตรศาสตร์	Sentiment Analysis on Thai-Language Restaurant Reviews(3).pdf	Completed	0.15 %

Match Overview

NO.	TITLE	AUTHOR(S)	SOURCE	SIMILARITY INDEX
1	การสร้างกรณีทดสอบการออกแบบคลังข้อมูล	ปิยภรณ์ สามสุวรรณ	จุฬาลงกรณ์มหาวิทยาลัย	0.15 %

Match Details

TEXT FROM SUBMITTED DOCUMENT	TEXT FROM SOURCE DOCUMENT(S)
ชสารบัญตารางตารางที่ 1 แผนการดำเนินงาน 3 ตารางที่ 2 ตารางแสดงตัวอย่าง C ้อมูลฝึกฝน 41 ตารางที่ 3 ตารางแสดงตัวอย่าง C ้อมูลชุดทดสอบ 42 ตารางที่ 4 การทดสอบ DropOut 52 ตารางที่ 5 การทดสอบ Batch Size 53 ตารางที่ 6 การทดสอบ Epoch 53 ตารางที่ 7 การทดสอบ Data Size 53 ตารางที่ 8 ผลระหว่างการฝึกที่ดีที่สุด 54 ตารางที่ 9 ผลการทดสอบ โมเดลพื้นฐาน Base Model เทียบกับ โมเดลที่ดีที่สุด Final	106ประวัติผู้เขียนวิทยานิพนธ์.....109ชสารบัญตารางตารางที่ 1 การคำนวณหาค่าระยะการแก้ไขระหว่างคำว่า INTENTION และ EXECUTION7ตารางที่ 2 รูปแบบการเขียนเอกสารการออกแบบส่วนข้อมูลตารางต้นทาง ในงานวิจัย.....16ตารางที่ 3 รูปแบบการเขียนเอกสารการออกแบบส่วนข้อมูลความสัมพันธ์ของตารางต้นทาง.....16ตารางที่ 4 รูปแบบการเขียนเอกสารการออกแบบส่วนข้อมูลความสัมพันธ์ของตารางต้นทาง.....16ตารางที่ 5 การสร้างกรณีทดสอบการออกแบบแต่ละระดับจากข้อมูลเอกสารการออกแบบ.....20ตารางที่ 6 การสร้างกรณีทดสอบจากเอกสารการออกแบบในระดับ conceptual schema21ตารางที่ 7 การสร้างกรณีทดสอบจากเอกสารการออกแบบในระดับ logical schema22ตารางที่ 8 การสร้างกรณีทดสอบจากเอกสารการออกแบบในระดับ physical schema23ตารางที่ 9 โครงสร้างข้อมูลสำหรับจัดเก็บกรณีทดสอบและคำสั่งทดสอบ.....26ตารางที่ 10 ความต้องการเชิงหน้าที่